

24/09/2024

Codice teams: sna5kf9

<https://www.jamovi.org/download.html>

TIPI DI VARIABILE

Le variabili si trovano alla base della statistica.

Cosa sono?

Def: è una proprietà operativizzata, cioè che ci consente una qualche misurazione, di cui si trovano gli stati della proprietà stessa.

Es: proprietà delle persone è il peso, ma come lo operativizzo? Scegliendo un'unità di misura.

- Si stabiliscono degli stati/delle modalità di questa proprietà che ci consente di dire in che stato si trova quella proprietà

Proprietà non direttamente misurabili: sono quelle proprietà che non si possono vedere essendo immateriali.

Questi stati/modalità possono essere diversi a seconda delle proprietà. A seconda della proprietà che si prende in considerazione avremmo bisogno di tipi di variabili diverse.

1946: il livello di misurazione di Stevens. Propose di classificare le variabili in 4 tipi:

1. Scala nominale
2. Scala ordinale
3. Scala di intervalli
4. Scala di rapporti

Questa classificazione si può considerare obsoleta perché complica le cose. Sono state rivolte delle critiche ed oggi si tende a pensare alle variabili come divise in 3 tipi, perché non tiene conto dell'evoluzione di matematica e statistica e non c'è una grossa differenza tra la scala di intervalli e la scala di rapporti;

1. **Variabili categoriali** (fa riferimento alla scala nominale): Quando lo stato/modalità della proprietà è un NOME (es. verde, azzurro, blu) nel senso che non esprimono delle quantità, che non si possono ordinare tra di loro;
2. **Variabili categoriali ordinate/ordinali**: quando lo stato/materia della proprietà è un NOME che esprime un qualche SENSO DI Quantità (es. molto, abbastanza, poco) che si possono ordinare tra di loro;
3. **Variabili cardinali** (unione tra scala di intervalli e scala di rapporti): quando lo stato/modalità della proprietà è un NUMERO che esprime una Quantità, utilizza i numeri cardinali e non i numeri ordinali.

Criterio scelto fino ad ora è quello della scala...

Ma si può utilizzare il criterio della posizione che la variabile occupa nel modello che noi vogliamo studiare:

1. **Variabili dipendenti**: è una variabile che cambia come conseguenza di altri fattori antecedenti;

2. **Variabili indipendenti:** è una variabile che ha la capacità di cambiare indipendentemente da altri fattori antecedenti, varia da sola e non come conseguenza di altri fattori;
3. **Variabili intermedie:** perché in un modello che viene costruito ci potrebbe essere una terza variabile tra x e y che completa il quadro con una variabile z

Es. variabili dipendenti ed indipendenti x e y

x = status socioeconomico
y = consumo di beni di lusso

Es. variabili dipendenti ed indipendenti x e y

x = genere
y = reddito

Questi collegamenti si chiamano IPOTESI.

Es. variabili dipendenti, indipendenti ed intermedie x y z

x = n pompieri
y = danni causati da incendio
z = vastità dell'incendio

Es. variabili dipendenti, indipendenti ed intermedie x y z

x = tazza di tè
y = durata della vita
z = sapersi prendere una pausa

la relazione tra x e y è una “variabile fantasma” perché si influenzano a vicenda ma entrambe dipendono dalla variabile z

il sapersi prendere una pausa fa variare la x e la y contemporaneamente

la vastità dell'incendio fa sì che più pompieri vengano chiamati, e la vastità dell'incendio aumenta i danni causati dallo stesso

N.B. la x con la presenza della z non diventa una variabile dipendente da z perché si parte dal primo modello più semplice e si va approfondendo.

Si può distinguere anche tra:

1. **Variabili endogene:** che stanno dentro il modello, indipendentemente dalla quantità di variabili;
2. **Variabili esogene:** che sono esterne al modello, o che entrano nel modello o che rimangono fuori o prima o dopo la soluzione del modello: serve a vedere cosa succede usando delle variabili nuove che possono essere di due tipi:
 - a. **Variabili esogene antecedenti:** stanno prima del modello costruito;
 - b. **Variabili esogene susseguenti:** stanno a valle del modello costruito.

Un'altra classificazione si ha tra:

1. **Variabili manifeste/osservate:** che si vedono nei modelli;
2. **Variabili latenti/non osservabili:** che sono nascoste dai modelli, o che sono nascoste o che sono inosservabili.
Latenti e non osservabili non sono la stessa cosa:
 - Latenti: sono variabili costruite con altre variabili, e di solito vengono fuori quando si utilizzano delle tecniche di analisi con molte variabili, che ad un certo punto mostra che esistono delle “meta variabili” che esprimono un concetto di cui non facilmente ci si accorge. Variabili che vengono fuori al seguirsi di un'esplorazione. È la variabile che si deve interpretare.

- **Non osservabili:** sono variabili di cui si sa come è composta ma non si sa come è composta, sono legato a concetti che non hanno un chiaro referente empirico. (es. variabile non osservabile = qualità della vita. Può essere composta da molte variabili, come salute, felicità ecc. di cui non si ha conoscenza concreta)

Variabile = variabilità sistematica + errore (quando si misura si può andare incontro ad un errore di misurazione di cui si deve tener conto)

Vi sono delle **fonti di errore:**

1. **Errori campionari:** errori che sono dovuti inevitabilmente alla procedura di misurazione/allo strumento;
2. **Errori non campionari:** errori umani.

ANALIZZARE LE VARIABILI

Bisogna fare delle scelte.

L'analisi si basa su un dispositivo per l'organizzazione dei dati che si chiama "matrice casi per variabili".

	Sesso	Età	Istruzione	Opinione 1	Opinione 2
Giovanni	M	19	3	1	S
Andrea	M	21	3	2	N
Filippo	M	26	4	2	S
Stefania	F	23	1	1	S
Antonio	M	22	2	4	S
Roberta	F	18	1	3	N

Le righe si chiamano casi, che in questo caso sono le persone.

Le colonne si chiamano variabili

Si tratta di analisi astratte, in contrapposizione all'analisi dei casi.

Si può studiare una matrice in senso orizzontale, in questo caso si studiano le singole persone, si dice che si sta facendo uno "studio concreto", si studiano le proprietà; o in senso verticale, in questo caso si studia colonna per colonna quindi solo le variabili e come si distribuisce la colonna, si perde lo studio delle persone e si sta facendo uno "studio astratto"

In verticale è uno studio generale, quindi astratto.

In orizzontale è uno studio particolare.

- **Analisi mono-variata/uni-variata:** riguardano una variabile alla volta, l'analisi di queste variabili prese ad una ad una tende a rispondere alla domanda "come si presenta il fenomeno?" o "come posso descrivere questo fenomeno?"
 - o Ricerca descrittiva
- **Analisi bi-variata:** riguardano due variabili, e l'analisi delle variabili tende a rispondere alla domanda "perché si presenta così il fenomeno?"
 - o Ricerca esplicativa
- **Analisi tri-variata:** riguardano tre variabili
 - o Ricerca esplicativa: si trova una risposta più completa visto che ci si trova in presenza di più variabili

- **Analisi multivariata:**

- Ricerca sia descrittiva sia esplicativa: risponde contemporaneamente al come si presenta il fenomeno ed ai perché del fenomeno.

ANALISI MONOVARIATA

Si fa una ricerca descrittiva.

Cosa si intende per “descrizione di una variabile”: significa provare a riassumere una distribuzione.

Es. 1

	Sesso	Età	Istruzione	Opinione 1	Opinione 2
Giovanni	M	19	3	1	S
Andrea	M	21	3	2	N
Filippo	M	26	4	2	S
Stefania	F	23	1	1	S
Antonio	M	22	2	4	S
Roberta	F	18	1	3	N

Se si prende in considerazione la variabile età, si deve riassumere ciò che è scritto in quella colonna in base alle righe di riferimento. È un lavoro che viene fatto per ogni colonna.

Per riassumere una distribuzione vi sono 3 modi:

1. Riassumere i dati in tabella / riassunzione tabellare

Es. 2

	v.a.	%	% cumulate
No, mai	132	8.8	8.8
2-3 volte l'anno	416	27.9	36.7
1 volta al mese	167	11.2	47.9
2-3 volte al mese	233	15.6	63.5
1 volta a settimana	415	27.8	91.3
Più volte a settimana	33	2.3	93.6
Altra religione	11	0.7	94.3
Non risponde	86	5.7	100
Totale	1.495		

Si tratta di modalità, valori assoluti e frequenze, percentuali, e percentuali cumulate.

% cumulate sono il calcolo delle percentuali di riferimento e quelle precedenti.

La frequenza è ..., che si omette una volta aggiunta la percentuale

2. Si calcolano le **misure di tendenza centrale**

Si tratta di moda, mediana e media -> calcolare la media

A livello matematico con le variabili categoriali non si può fare molto, con le variabili categoriali ordinali nemmeno a livello matematico ma si può mettere un ordine.

Con le variabili cardinali invece si possono fare molte cose.

Ciascuna delle variabili, poiché fatte diversamente, subirà un trattamento diverso seguendo degli indicatori diversi.

- La **moda** viene utilizzata per le variabili categoriali: è la risposta più frequente o la risposta che va più di moda;
- La **mediana** viene utilizzata per le variabili categoriali ordinali: ci sono due modi:
 - o È la risposta nella quale si incontra per la prima volta il 50% delle percentuali cumulate (es. 2 la mediana è “2-3 volte al mese” perché nelle percentuali cumulate il valore è 63.5 nel cui interno si trova per la prima volta il 50%);
 - o Si prendono tutte le risposte e si mettono in maniera ordinata in fila, si traccia una linea verticale e
Se il numero delle osservazioni è pari si hanno due valori che si trovano ambo i lati della mediana.
Se il numero delle osservazioni è dispari, il valore è che viene attraversata dalla mediana stessa.
- La **media** viene utilizzata per le variabili cardinali: si sommano i valori e si dividono per il numero di variabili.

Le varie osservazioni le chiamano X_i (x con i), vengono messe in fila
Es.

2 -> x_1 se volessimo fare la media si farebbe: $\frac{x_1+x_2+x_3+x_4+x_5}{n}$
 2 -> x_2 si potrebbe scrivere anche: $\frac{x_1+x_2+\dots+x_n}{n}$
 4 -> x_3
 5 -> x_4
 4 -> x_5

La vera formula dal punto di vista statistico si utilizza la sommatoria, che indica il sommare tutto ciò che viene dopo il valore di riferimento, $\sum x_i$ con $i=1$ (sommatoria di x_i con i che va da i a n) e si divide tutto / n .

Le medie si segnano come x con il trattino di sopra.

3. Si misura la **variabilità del fenomeno**/della variabile

26/09/2024

Misura di dispersione o della variabilità del fenomeno

Misure di variabilità:

Ci si può fidare della media per le misure di tendenza centrale? Tendenzialmente no perché due situazioni differenti può essere lo stesso risultato.

					MEDIA
A	2	2	2	2	2
B	0	0	8	0	2

Moda, mediana, media avranno le loro singole misure di variabilità.

La **moda** avrà come misura di variabilità, l'**indice di eterogeneità**, serve per le variabili nominali e si calcola: $E = 1 - \sum_{i=1}^k p_i^2$ (1- sommatoria di “p con i” al quadrato) **indice di eterogeneità assoluto**

Le p sono le proporzioni con le quali troviamo una risposta ad una domanda.

La proporzione è quella che chiamavamo “frequenza”.

Es. Bibite = 100 persone bevono bibite

Coca cola = 30 preferiscono questa -> per trovare la proporzione $\frac{30}{100}$: 0.3

Fanta = 20 preferiscono queste -> per trovare la proporzione $\frac{20}{100}$: 0.2

Sprite = 50 preferiscono queste -> per trovare la proporzione $\frac{50}{100}$: 0.5

Se questi li moltiplichiamo *100 troviamo le percentuali.

$E = 1 - \sum p^2 = 1 - (0.3^2 + 0.2^2 + 0.5^2) = 1 - (0.09 + 0.04 + 0.25) = 1 - (0.38) = 0.62$ che diventa l'indice di eterogeneità che fa vedere quanto è eterogenea la distribuzione.

Indice di eterogeneità relativo

$$E(rel) = \frac{k}{k-1} * E$$

Es.

Reddito diviso in quattro fasce di reddito:

1. Poveri
2. Reddito medio basso
3. Reddito medio alto
4. Ricchi

L'indice di eterogeneità è: $E = 1 - \sum_{i=1}^k p_i^2$

$$E = 1 - (0.6^2 + 0.2^2 + 0.1^2 + 0.1^2) = 1 - 0.51 = 0.49$$

$$E(rel) = \frac{k}{k-1} * E = \frac{4}{3} * 0.49 = 0.65$$

Differenza interquartile, per le variabili ordinali: è la differenza tra valore massimo e valore minimo.

11111 2222 | 2 333 444444

La mediana è 2

Si deve prendere la distribuzione e dividere in quattro parti uguali

1111 | 1 2222 | 2 333 4 | 44444

25% 50% 75% 100%

Si devono prendere i valori centrali, eliminando i valori più bassi ed i valori più alti. Ci rimane quindi:

| 1 2222 | 2 333 4 |

La differenza interquartile si trova facendo valore massimo e valore minimo, cioè 4 ed 1: $4-1=3$

C'è una distanza di 3 tra il valore minimo ed il valore massimo.

Varianza, per i valori cardinali

Deviazione standard, per i valori cardinali

Es. acquisiti annui di vinili nel gruppo A.

					MEDIA
A	3	3	4	2	3

Varianza: si calcola quanto ogni valore è diverso dalla media.

Si fa la differenza tra tutti i valori e la media, quindi:

$$x_i - \bar{x} \quad x_i - x$$

3 - 3 = 0 Le prime due persone acquistano lo stesso numero di vinili.

$$3 - 3 = 0$$

4 - 3 = 1 La terza persona acquista un vinile in più.

2 - 3 = -1 La quarta persona acquista un vinile in meno.

Facendo la somma viene 1 + (-1) = 0.

Si risolve il problema eleva tutto al quadrato.

$$(x_i - \bar{x})^2$$

$$0^2 = 0$$

$$0^2 = 0$$

$$1^2 = 1$$

$$-1^2 = 1$$

La varianza si calcola quindi: $\frac{\sum (x_i - \bar{x})^2}{n} = \sigma$

La deviazione standard invece si calcola: $\sqrt{\frac{\sum (x_i - \bar{x})^2}{n}}$


Ci sono due aspetti dell'analisi mono-variata che sono di contorno:

- Rappresentazioni grafiche

- Box plot (box and whiskers plot)

Gli outliers/single data point/valori anomali sono quei valori eccessivamente alti o eccessivamente bassi che sono spesso frutto di un errore per la quale la rappresentazione si distorce: quindi normalmente si eliminano

- Diagramma a barre, quando si utilizzano variabili ordinali
- Istogramma, quando si utilizzano le variabili cardinali
- Differenze tra gruppi




Vi è il principio della normalità della distribuzione.

- Test di normalità

È il test che si chiama Shapiro-Wilk secondo il quale ci restituisce dei numeri, tra cui "p" che dovrebbe normalmente essere più grande > 0.05

Si deve capire se la curva ha un determinato andamento:



Questa curva significa anche:

- Asimmetrica/Skewness: una curva normale è simmetrica all'asse delle y, la parte di sinistra e la parte di destra devono essere speculari
Sarà negativa se i valori si concentrano di più verso sinistra.
Sarà positiva se i valori si concentrano di più verso destra.
L'importante è che non superi la soglia di 3.
- Curtosi/Kurtosis: ha a che fare con la testina della curva normale, che sia una punta, un picco o una punta curva.
Misura la curvatura della testina alla curva normale.
Leptocurtica: se la testina è allungata verso l'alto, ed ha un valore positivo.
Laticurtica: se la testina è più abbassata, ed ha un valore negativo.

08/10/2024

Questione che si pone con l'analisi mono-variata: quando ho più di una distribuzione e ne voglio effettuare una comparazione, si pone il problema di scala. Per depurare le distribuzioni dalla scala di misura si può provvedere ad una trasformazione delle variabili. Lo scopo è quello di creare nuove distribuzioni che abbiano delle caratteristiche comuni, si può fare in due modi:

1. Effettuando una normalizzazione: creare una nuova distribuzione che ha come campo di azione tra 0 (valore minimo) e 1 (valore massimo).

$$\text{Si fa: } x_i^* = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}}$$

Quando si deve fare una comparazione tra le diverse scale, si fa il calcolo della normalizzazione per far sì che appartengano alla stessa scala, che va appunto da 0 a 1.

2. Effettuando una standardizzazione: crea delle nuove distribuzioni equivalenti, che avrà una media 0 ed una deviazione standard 1.

$$\text{Si fa: } z_i = \frac{x_i - \bar{x}}{SD}$$

SD= standard deviation/deviazione standard.

Quando si ha a che fare con la statistica differenziale, è più opportuno ragionare in trasformazioni Z, cioè, effettuando una standardizzazione.

ANALISI BIVARIATA

Si passa da una variabile a due variabili.

Quando si considerano le variabili a due a due, il livello dell'analisi si alza, perché si passa dalla descrizione alla spiegazione chiedendoci non più come si presenta un fenomeno ma perché si presenta in quel determinato modo il fenomeno.

Si hanno variabili indipendenti (x) e variabili dipendenti (y). La y è dipendente perché si sostiene che varia solo al variare della variabile x: si ha un fenomeno che ha la sua variabilità, si capisce solo se è associata ad una variabile dipendente che ne definisce la funzione.

Due modi per verificare come le variabili entrano in relazione tra di loro:

1. Tabella di contingenza: quando si hanno delle variabili ordinali e nominali. Si utilizza per controllare come due variabili stanno insieme.

Es.

(livello di istruzione)	Maschio	Femmina	Totale
Bassa	32	87	119
Alta	156	145	301
Totale	188	232	420

I colori in arancione si chiamano “numeri marginali” che si trovano facendo la somma tra i valori.

La logica di questa tabella è capire se esiste una relazione tra l'essere maschio/femmina ed avere la possibilità di studiare. Per studiare la presenza di questo fenomeno costruisco una tabella del genere, che non aiuta poiché è espressa in numeri assoluti.

Si deve calcolare la percentuale di colonna:

(livello di istruzione)	Maschio	Femmina	Totale
	17%	37.5%	28.3%
Bassa	32	87	119
	83%	62.5%	71.7%
Alta	156	145	301
Totale	188	232	420
	100%	100%	

Si vede che c'è uno sbilanciamento tra il livello di istruzione tra la percentuale di maschi e di donne.

Servirebbe un indice che dice complessivamente quando sono legate tra di loro le variabili. All'aumentare delle categorie le tabelle divengono più complicate.

2. Diagramma a dispersione (scatterplot): si usa quando le variabili sono cardinali, si può fare per le variabili ordinali quando queste hanno tante categorie. Si parte dalla matrice di variabili dipendenti e variabili indipendenti, x e y.

Es.


	X, anno di corso	Y, soddisfazione per i servizi unipa
Franco	1	3
Ciccio	2	4
Mimmo	3	5
Enzo	2	2

Totò	4	7
------	---	---

È un grafico, sistema di assi cartesiani:

- Se accade che i punti formano una retta, significa che le due variabili sono legate tra di loro: “linea di tendenza”. La retta deve passare il più vicino possibile a tutti i punti calcolati (per quando possibile).

In questo caso la retta afferma che man mano che l'anno di corso aumenta, aumenta anche la soddisfazione dei servizi.



Ci manca il numero che conferma quanto siano legate le variabili. Si deve cercare la:

- Forza della relazione: cioè, di quanto varia la y, variabile dipendente, al variare delle x, variabile indipendente. Può aiutare per fare delle previsioni.
- Significatività della relazione: si riferisce ad un problema, se si cambia campione, la relazione cambia anch'essa? Se si devono effettuare delle previsioni questo possibile cambiamento può causare confusione. La significatività misura quanto è dovuta ad un caso la relazione che si calcola.

Chi-quadro (χ^2): strumento che calcola quanto effetto ha la variabile dipendente sulla variabile indipendente. È un indice che si basa sul test di significatività dell'ipotesi nulla (NHST): si stabilisce un'ipotesi nulla, ovvero ipotesi secondo la quale non vi è alcuna relazione, e si cerca di capire quanto si è distanti rispetto il nulla preso in considerazione, e più si è lontani da quel valore meglio è.

Es.

	Favorevoli alla pena di morte	Contrari alla pena di morte	
Maschi	100	20	120
Femmine	10	150	160
	110	170	280

Si eliminano i valori più piccoli.

All'interno delle celle vi sono i valori osservati.

Per calcolare il Chi-quadro si deve calcolare il nulla. Si devono prendere i valori marginali in base ai valori osservati diviso il totale:

$$\text{Cioè: } \frac{110 \cdot 120}{280} = 47.14$$

$$\text{E poi: } \frac{170 \cdot 120}{280} = 72.85$$

$$\text{E poi: } \frac{110 \cdot 160}{280} = 62.85$$

$$\text{E poi: } \frac{170 \cdot 160}{280} = 97.14$$

	Favorevoli alla pena di morte	Contrari alla pena di morte
Maschi	47.14	72.85
Femmine	62.85	97.14

All'interno di questa tabella vi sono i valori attesi.

Il CHI-quadrato si calcola:

$$X^2 = \sum \frac{(f_e - f_o)^2}{f_e}$$

Si può fare con le variabili categorizzati, non cardinali a meno che non siano divisi in categorie.

Significatività= probabilità che la relazione sia data dal caso, che cambiando campione la relazione persiste o meno. Viene espressa come probabilità, più basse è la probabilità che la relazione sia dovuta al caso meglio è. Viene espressa in percentuale espressa nella tabella Jamovi nella colonna "p".

C'è una soglia sotto la quale non si può risalire? Quando la "p" avrà un valore più grande del 5% perché non esiste la relazione, sopra il 5% non vi è relazione, sotto il 5% sì.

"df" significa degrees of freedom, gradi di libertà, cioè quelli che hanno a che vedere con le dimensioni della tabella.

Quando si calcola il Chi-quadro, si calcola: (numero delle righe-1) * (numero delle colonne-1)

Sono importanti perché influenzano sia p che il Chi-quadro.

Dibattito sull'opportunità dei test di significatività:

- Il Chi-quadro diventa più grande man mano che aumenta n;
- Il Chi-quadro dà come risultato un esito binario, alla conclusione del quale bisogna tenere il risultato o rigettarlo, (retain/reject);
Per quale soglia di 0.05.
- Si dimostra con il chi-quadro che quello che si ha è meglio di niente.
- Alternative a p: size effect, dimensione effetto, cioè confronto tra modelli.

Come si può depurare nel Chi-quadro l'effetto di n?

Tre tappe, in base alle variabili:

1. Associazione: quando si accoppiano due variabili di tipo nominale;
Si utilizzano con il Chi-quadrato due indici derivati:

- a. Φ (phi);
- b. V di Cramér, che ha un massimo e minimo teorico tra 0 e 1;
Si aiutano reciprocamente.

Vi sono altre misure chiamate "misure riproduzione proporzionale di errore", che variano tra 0 e 1, ed affermano di quanto si riduce l'errore nel predire una variabile conoscendo l'altra:

- c. λ (lambda) di Goodman
- d. τ (tau) di Kruskal

2. Cograduazione: quando si accoppiano due variabili di tipo ordinale;
Si aggiunge il segno della relazione, che è + o -

- a. τ_c (tau-c) di Kendall
- b. γ (gamma) di Goodman e Kruskal
- c. d di Somers (asimmetrica)
- d. ρ (rho) di Spearman (simmetrica)

3. Correlazione: quando si accoppiano due variabili di tipo cardinale

- a. r di Pearson, numero compreso tra 0 e 1 che può essere + o -;

- b. Significatività
- c. Assumptions (presupposti, precondizioni):
 - i. Linearità: Presuppone che succedano delle cose tra le due variabili, richiede che la relazione tra le due variabili abbia natura lineare, se questa non c'è non si può calcolare la r di Pearson (non deve essere una linea precisa ma si tratta di un andamento).
 - ii. X e Y devono avere una distribuzione normale
 - iii. Omoschedasticità: i residui della retta che abbiamo disegnato non devono essere funzione della X, della variabile indipendente.
 I residui/scarti sono le distanze che si vedono di ogni puntino dalla retta: si possono considerare come degli errori di previsioni che sono stati calcolati. Questi residui devono essere tenuti in considerazione.
 Non devono essere funzione di X, cioè che le distanze dei puntini dalla retta non devono aumentare/diminuire all'aumentare/diminuire di X.
 Come si controlla? Devono essere degli errori casuali.
 Con la funzione "standard error" si può vedere la media degli errori in quei punti della retta.

10/10/2024


REGRESSIONE

- REGRESSIONE LINEARE SEMPLICE I

Si fa ricorso alla regressione perché si prova a dare risposta alla domanda: "è possibile prevedere/stimare il valore delle Y conoscendo il valore della X?".

I modelli della regressione sono modelli predittivi.

Nell'esempio precedente, è la retta che ci dà la possibilità di prevedere il valore della Y. La retta si chiama "retta di regressione", che è la retta che prova a incontrare tutti i punti, interpola i punti, è il modello predittivo della realtà.



Siccome è una retta è descritta da un'equazione: $Y = a + bX$

Quando mettiamo un valore ad "a" ed un valore a "b" possiamo venire a conoscenza del valore della Y. Questo modello è molto generico, non appena si sostituiscono i valori alle variabili a/b diventa un modello concreto, ed in base al valore di X si trova il valore di Y.

Come trovare i valori di "a" e "b"?

La "a" si chiama "intercetta della linea": il punto in cui l'asse delle Y si interseca con la retta.

La "b" si chiama "coefficiente angolare" della retta: cioè, l'inclinazione della retta, più è inclinata la retta allora più velocemente cambiano i valori di Y. Un valore di "b" positivo ed elevato significa che Y cresce rapidamente al crescere di X. Un valore di "b" negativo ed elevato significa che y cala molto rapidamente al crescere di X.

Questo avviene nel caso ideale.

Nella realtà invece si deve tener conto degli errori, cioè dei residui/scarti, quindi l'equazione diventa:

$$Y = a + bX + e$$

e = residuo/scarto

Si dovrebbe distribuire normalmente, cioè con una forma a campana che implica la casualità degli errori.

Come si calcolano “a” e “b”? Si calcolano minimizzando l'errore totale che si riesce a costruire la retta di regressione: tramite il metodo dei minimi quadrati: Ordinary Least Squares (OLS).

...

“b” è di quanto cambia il valore della Y

- REGRESSIONE LINEARE SEMPLICE II

Vi sono due tipi di “b”:

- b come coefficiente angolare/di regressione;
b corrisponde alla variazione prodotta sulla Y dalla crescita di una unità di X.
- beta, b standardizzato: è un valore che va da 0 a 1.
Beta corrisponde alla variazione prodotta sulla Y standardizzata dalla crescita di una unità della variabile X standardizzata, varia tra -1 e + 1-
Beta corrisponde alla r di Pearson.

Quanto ci si può fidare dei valori? Si deve controllare “p” per comprendere quanto il calcolo sia dovuto al caso.

La “t” è la $\frac{\text{stima}}{\text{errore standard}}$ che serve a trovare p.

I valori estremi si chiamano “outliers” che stanno al di fuori del campo normale dei punti. I punti estremi determinano una distorsione su b, si possono eliminare oppure si abbassano al valore più basso successivo, oppure vengono sostituiti con il valore medio: sono strategie che ci consentono di contenere determinate distorsioni.

Bontà del modello: se volessimo avere un numero che dice in totale quanto è buono questo modello, vi è una misura che aiuta a raggiungere questo obiettivo che si chiamano “misure di bontà di adattamento” / “Misura di Goodness fit”. Si deve fittare il modello ai dati e si deve capire quando fitta la retta sui dati.

Sono due misure che si chiamano:

1. Coefficiente di correlazione multipla,
2. Model fit measure, coefficiente di determinazione.

Ci dicono in che misura questo modello è riuscito a adattarsi ai dati: più il numero si avvicina ad 1, è perfetto.

La r di Pearson afferma quanto il modello si è adattato ai dati.

La misura che si prende in riferimento è il coefficiente di determinazione: r^2 , in che misura sono riuscito a riprodurre la varianza del fenomeno.

Quanto più basso è “p”, quindi il caso influenza minormente, meglio è.

ANALISI TRIVARIATA

- Correlation is not causation

La correlazione non è la causazione, non sono direttamente legate l'una all'altra.

Si utilizza una terza variabile, Z, che è la variabile di controllo.

Vi sono delle relazioni fantasmatiche che spariscono all'introduzione di una variabile "Z" in quanto questa influenza sia la variabile X che la variabile Y, che serve a sciogliere le relazioni "spuria". Si colloca nel medio tra la X e la Y.

Come si trovano queste variabili? Si fa riferimento ad una teoria che consenta di trovare una terza variabile.

Come studiare l'effetto della terza variabile? Si deve studiare in che modo la variabile Z influenza la relazione tra X e Y:

- Controllo, via concreta per variabili nominali, cioè quando le variabili Z sono variabili nominali. Come effettuare questo controllo: si costruiscono due sotto campioni rispetto ai campioni generali.
- Depurazione: fa ricorso a strumenti statistici e si utilizza quando le variabili Z sono variabili cardinali.
 - o Coefficiente di correlazione parziale
 - o Mediazione
 - o Moderazione

Tipi di relazione:

- Relazione tri-variata Spuria
- Relazione tri-variata Indiretta:
 - o La Z in questo caso prende il nome di variabile interveniente;
 - o Il nesso causale c'è ma è indiretto, c'è una relazione X e Y e può essere indiretto o sia diretto che indiretto;
- Relazione tri-variata Condizionata, X e Y sono collegate ma la loro relazione varia al variare di Z.

15/01/2024

REGRESSIONE MULTIPLA


Si deve tener conto del fatto che i fenomeni sociali ecc. sono multi-causali o multifattoriali: più è complesso un fenomeno più è probabile che si abbia bisogno di più variabili.

Questa ci dà la possibilità di utilizzare diverse variabili.

Per realizzare una regressione multipla si fa riferimento ai modelli lineari generalizzati: si avrà un modello generico di riferimento che prevede una serie di variabili indipendenti X che influenzano la variabile dipendente Y.

Il modello che si va costruendo è un modello perfettamente conoscibile ma iper-semplificato.

Si chiama perfettamente conoscibile perché si riesce a sapere, tramite un coefficiente angolare "b", come tutte le variabili indipendenti influenzano la variabile dipendente.



Si dice iper-semplificato perché si possono prevedere solo percorsi diretti tra le X e la Y.

x_4

Questo modello viene descritto da un'equazione.

Applicazioni:

- Stimare/predire un valore attraverso la misurazione di una serie di caratteristiche note, cioè le variabili X;
- Depurare un effetto apparentemente causale da componenti spurie;
- Mediazione e moderazione.

Si tratta di un'equazione con più regressori (iperpiano): $Y = a + b_1X_1 + b_2X_2 + b_3X_3 + \dots + b_nX_n + e$

L'iperpiano è un ente geometrico che non è realizzabile.

Il modello fa sempre ricorso alla tecnica dei minimi quadrati (OLS, ordinary least squares)

I coefficienti b rappresentano l'effetto di un variabile X_i su Y quando tutte le altre restano costanti.

Ogni coefficiente viene accompagnato da un test di significatività (t) e da p.

È possibile calcolare l'intervallo di fiducia della stima con SE: $b - z\sigma_b < b_{reale} < b + z\sigma_b$

Z ha il valore di 1.96 se la percentuale è del 95%; varia al variare della percentuale, o diventa costante per convenzione.

Con le variabili categoriali ci può essere un problema che può essere superato utilizzando uno stratagemma: si attribuiscono dei valori di 0 o 1 di presenza e assenza.

Si parla di due tipi di regressione:

1. Sequential/hierarchical regression: le variabili vengono inserite secondo teoria;
2. Stepwise regression: introduce le nuove variabili attraverso un algoritmo

...

Assunti del modello:

- Linearità del modello: qualora questo iperpiano fosse qualcosa di curvilineo non si potrebbe utilizzare in quanto si deve utilizzare il modello lineare:
 - o Si può scomporre l'effetto non lineare in più effetti lineari parziali;
 - o Introdurre regressori quadratici o di grado superiore;
- Additività e indipendenza degli effetti:

Si deve accettare che gli effetti si cumulino, si sommino;

Le variazioni di una indipendente, cioè la X, non devono influenzare le variazioni di un'altra variabile indipendente, cioè di un'altra X.

- o Interazione, se l'effetto di un regressore varia rispetto ad un altro regressore: ogni variabile cammina per conto proprio e se ci deve essere una interazione tra le variabili, cioè che una X influenza un'altra X, questo deve essere gestito;
- Corretta specificazione del modello: il modello deve essere scritto bene e pensato bene, cioè:
 - o Non vanno inserite variabili intervenienti;

- Proprietà statistiche, da controllare:
 - I casi del campione devono essere estratti in modo indipendente;
 - La Y deve essere cardinale ed il suo errore, residuo, distribuito normalmente
 - Omoschedasticità:
 - La varianza dei residui è costante, i residui non sono funzione dei regressori;
 - Assenza di multicollinearità: cioè, assenza di correlazione tra le variabili indipendenti
 - VIF (variance inflation factor) < 10: ma < 4 sarebbe meglio;
 - Tolerance > 0.25: ma non si deve mai scendere < 0.10.

17/10/2024

Vedere come si possono usare i modelli di regressione nella pratica di ricerca.

Scopo della regressione:

- Predizione, la regressione ha funzione di prevedere i valori di y conoscendo i valori x;
- Controllo di relazioni spurie:
 - Correlazioni parziali:
Certe volte le relazioni tra x e y sono fantasmatiche, si cerca di produrre un modello più realistico introducendo una nuova variabile.
 - Costruisci un modello, con Z e Y correlate, e segna i coefficienti iniziali;
 - Inserire le variabili antecedenti al modello iniziale;
 - Se cambiano i “b” iniziali, diminuendo e allineandosi tra loro, la relazione XZ è spuria.
- Controllo di relazioni indirette, se hai tre variabili si fa una mediation analysis:
 - Costruire un modello in cui si trova la correlazione X e Y;
 - Inserire una variabile interveniente (M) al modello iniziale;
Il percorso che va dalla variabile indipendente alla variabile interveniente si chiama “A”
Il percorso che va dalla variabile indipendente alla variabile dipendente si chiama “C”
Il percorso che va dalla variabile interveniente alla variabile dipendente si chiama “B”
 - Se X e Y sono correlate per via di M, allora b_x in $X \rightarrow Y$ non sarà più significativo;
 - Full, partial, null mediation (confronta effetto diretto sull’effetto totale) + Sobel Effect:
 - Full: è un unico percorso indiretto per cui la variabile M è la sola responsabile della relazione tra la variabile X e Y;
 - Partial mediation: quando un po’ della variazione di Y è spiegata da C, relazione diretta, e un po’ della variazione di Y è spiegata dalla M, relazione indiretta;
 - Null mediation: quando non vi è relazione indiretta nella relazione tra la variabile X e Y.

Test di Sobel è un test che misura la mediazione, (sobel test: quantpsy.org),

- Controllo di relazioni condizionate, se si hanno tre variabili si fa la moderation analysis:
 - Costruisci un modello con le tre variabili;
 - Inserisci una variabile che è il prodotto dei regressori X e Z;
 - Stiamo introducendo un regressore non-lineare
 - First/main order effects: sono gli effetti senza interazione;
 - Second/indirect order effects: sono gli effetti che provengono dagli effetti indiretti, di secondo ordine.

Quando si fa l’analisi della moderazione si devono fare i confronti tra quelle stime e vedere quale vale di più.

- La nuova variabile che è stata inserita per esserci una moderazione deve essere significativa.

22/10/2024

ANALISI FATTORIALE

L'analisi fattoriale è una tecnica di un'analisi multivariata: le variabili prese in considerazione sono molte.

Queste variabili si possono incontrare dopo la somministrazione di un questionario. Viene fuori l'esigenza di accorpare le variabili per crearne dei pacchetti che abbiano un significato.

Requisiti:

- L'analisi fattoriale può essere utilizzata per variabili cardinali o quasi cardinali; tuttavia, è vero che non è infrequente l'estensione della tecnica a variabili ordinali o a variabili dicotomiche. Le variabili quasi cardinali sono delle variabili ordinali che hanno una caratteristica, sono variabili per le quali ha senso fare delle operazioni matematiche.
- L'analisi fattoriale non va fatta su variabili che riguardano contemporaneamente ambiti diversi, dovrebbero riguardare ambiti omogenei (es. ambito economico, ambito del razzismo, ambito dei test attitudinali, ecc.): vanno selezionate le variabili in base ad un tema/ambito.
- Meglio che non ci siano gravi squilibri nelle distribuzioni di frequenza delle variabili messe in analisi e che il campione sia grande: secondo il teorema del limite centrale, man mano che aumentano il numero dei casi allora le stime diventano sempre più robuste.
Se è >100, non è necessariamente probabilistico.
Si usano molte variabili e però queste hanno varia modalità (es. molto, abbastanza, poco, per nulla) e per ogni casella ci dovrebbe essere un numero sufficiente di persone, senza che vi siano categorie troppo squilibrate perché in caso di squilibrio non aiuta computazionalmente la tecnica a funzionare. Si dovrebbe fare una analisi monovariata per vedere se tutte le categorie sono tutte abbastanza rappresentate.
- Non si dovrebbero sottoporre ad analisi fattoriale variabili fra le quali potrebbe intercorrere un rapporto di associazione o casuale: variabili, cioè, che sono fra loro fortemente correlate, possono essere correlate ma non deve presentarsi un rapporto causale (se vi sono variabili fortemente correlate tra loro basta prenderne una).

Obiettivi:

- Riduzione dei dati: quando si hanno matrici gigantesche, soprattutto nelle colonne, l'analisi fattoriale aiuta a restringere i casi impacchettando le variabili;
- Uso di super-variabili/ variabili latenti, cioè variabili composte che si trasformano in un'unica sola variabile;

Possono essere:

- Variabili latenti, che spuntano per effetto dell'utilizzo di questa tecnica;
- Variabili non osservabili, che vengono fuori dal percorso inverso del ricercatore che pensa a degli indicatori che combinati possano misurare un dato concetto, che di per sé non è direttamente osservabile.

Si fa una verifica per cercare di capire se quell'insieme di variabili funziona per misurare il dato concetto.

Due percorsi che sono simili dal punto di vista tecnico in quanto la tecnica alla fine è la stessa.

- A proposito di verifica, quando si scelgono le variabili e si mettono assieme il problema che può presentarsi è, tutte le variabili scelte servono a misurare la stessa cosa o alcune variabili misurano un sotto-concetto? Quando si scelgono le domande nel questionario, queste cosa mi aiutano a misurare?
- Misurazione e controllo di concetti non direttamente osservabili
 - Controllo di unidimensionalità

L'analisi fattoriale mettendo insieme le variabili le più simili possibili, si potrebbe accorgere della presenza dei sotto-blocchi, che fanno parte del macro-concetto e poi si hanno due o diverse misurazioni.
 - Stima dei pesi degli indicatori:
 - Quando si scelgono gli indicatori, questi pesano tutti alla stessa maniera? Non tutti ovviamente hanno lo stesso peso, vengono indicati dalla procedura statistica.

L'analisi fattoriale ci dice quanto pesano gli indicatori.
 - Giudizio sulla validità dei rapporti di indicazione:

L'analisi fattoriale aiuta ad esprimere un giudizio sulla validità del rapporto di indicazione: quanto sono stati coperti i livelli semantici di quel concetto in questione.

Nel caso in cui si ha un costrutto, questo consente di verificare come si è lavorato e fa esprimere un giudizio sulla validità dei rapporti di indicazione, cioè il rapporto tra gli indicatori ed il concetto

Nel 900 è venuta fuori una scuola che si è contrapposta al vecchio modo di fare analisi fattoriale esplorativa, e si è trovata una reazione si è chiamata analisi fattoriale confermativa, cambiando il paradigma in cui prima si fa uno sforzo teorico/concettuale e successivamente si mette alla prova. È più complicata di quella esplorativa ed apre un nuovo fronte di discussione perché lavorando nell'analisi fattoriale confermativa prende posizioni ed inserisce dei parametri che sono opinabili in quanto l'arbitrarietà dei ricercatori è elevata.

L'analisi fattoriale confermativa ha dato luogo ad un fronte, cioè l'approccio SEM, Structural Equation Modeling.

Non esiste solo un modo di fare analisi fattoriale: intanto vi è la differenza tra esplorativa e confermativa. Andando più in profondità, l'analisi fattoriale è una famiglia di tecniche che comprende tre sottofamiglie:

1. Analisi fattoriale esplorativa;
2. Analisi fattoriale confermativa;
3. Analisi delle componenti principali: la tecnica che è nata per prima, i cui limiti hanno portato i ricercatori a perfezionare i modelli perfezionando l'analisi fattoriale che oggi è composta da tutte e tre le tecniche.

Nell'analisi fattoriale si dice che si utilizzano super-variabili, che per la terminologia esatta prendono il nome di Fattori, o dimensioni/costrutti latenti, cioè gli insiemi di variabili che escono fuori dall'analisi fattoriale.

Nell'analisi delle componenti principali, le super-variabili prendono il nome di Componenti.

I fattori sono dei costrutti, degli insiemi di variabili, che fanno riferimento a dei concetti latenti e quindi l'analisi fattoriale viene utilizzata quando si ha a che fare con le variabili latenti/ipotetici, quelle che vengono fuori ad insaputa del ricercatore.

Le componenti sono reali, sono realizzate attraverso trasformazioni di variabili reali, sommando materialmente le diverse variabili: vengono utilizzate per misurare concetti non osservabili.

Poiché un fattore è ipotetico, può spiegare la correlazione tra le variabili senza essere completamente definito da esse. La scoperta delle variabili latenti è una rivoluzione nell'ambito delle scienze sociali perché permette di arrivare a dei concetti molto complessi bypassando procedimenti ancor più complessi.

Dal punto di vista statistico, mentre l'analisi fattoriale stima un modello che ha lo scopo di riprodurre la struttura di associazione tra un certo numero di trasformazione delle variabili prese in esame (modello significa qualcosa che si avvicina alla realtà in maniera approssimativa); l'analisi delle componenti principali è una semplice trasformazione delle variabili prese in esame e si ottiene un costrutto.

- I risultati delle due analisi sono spesso molto simili, pur essendo diverse le tecniche;
- Il problema dell'analisi fattoriale è che il ruoto attivo del ricercatore, dell'ampia arbitrarietà, porta a dare delle giustificazioni.

L'analisi delle componenti principali è più chiara, si scelgono delle variabili e ciò porta a delle scelte facilmente giustificabili a differenza dell'analisi fattoriale.

Procedura:

1. Costruzione della matrice di associazione/correlazione:
L'analisi fattoriale non parte dalla matrice casi per variabili, ma parte dalla matrice di correlazione/associazione. In realtà non siamo noi a fare le matrici di correlazione/associazione ma Jamovi lo fa automaticamente.
Si fa con variabili cardinali o quasi cardinali.
2. Scelta della tecnica di estrazione dei fattori/componenti:
Si deve dire al software come si estraggono i fattori/le componenti, e vi sono diverse tecniche di estrazione.
 - a. Analisi fattoriale confermativa;
 - b. Analisi fattoriale esplorativa;
 - c. Analisi delle componenti principali.
3. Scelta del numero di fattori/componenti da considerare:
Non solo si deve dire al software come estrarre le variabili, e si deve dire quante devono essere: normalmente sono due;
4. Eventuale rotazione dei fattori/componenti
5. Calcolo dei punteggi fattoriali, factor scores:

Se si trova la super-variabili, ogni fattore/componente avrà un valore corrispondente e questo valore equivale al punteggio fattoriale.

Costruzione della matrice

L'analisi fattoriale non sfrutta direttamente le colonne della matrice casi per variabili ma ha bisogno di creare la matrice di correlazione, cioè quella di Pearson, ovvero una tabella in cui ci saranno in righe e colonne le variabili e poi si farà un incrocio per vedere il valore di correlazione tra le due.

La matrice deve rispondere ad alcuni requisiti per essere analizzata attraverso analisi fattoriale, bisogna quindi studiare la matrice, la quale non dovrebbe ospitare alcun valore superiore al 0.95 perché indicherebbe multicollinearità, ma avere almeno alcuni valori superiori a 0.5.

Ciò si fa perché l'analisi fattoriale cerca di spiegare come mai si trovano determinate correlazioni nella matrice associazione per correlazione e a cosa sono dovute queste correlazioni più alte tra diverse variabili. L'idea è che alcune variabili tra loro siano più strette per effetto della presenza di una super-variabile che spiega perché alcune sono vicine tra di loro. Si deve capire da dove viene questa relazione concomitante tra variabili.

- Ogni matrice contiene una certa variabilità;
- L'analisi fattoriale prova a spiegare la variabilità della matrice individuando pochi fattori anziché considerare tutte le variabili: questa operazione ci consente di risparmiare sulle variabili che si tengono in considerazione.

Scelta della tecnica dell'estrazione dei fattori

L'idea che sta alla base dell'analisi fattoriale è che il fattore/componente sia presente ogni volta che troviamo un gruppo di variabili strettamente correlate fra loro e relativamente meno correlate con altre.

Si deve capire come poter scomporre/dividere la variabilità che si è vista prima, con riferimento alle singole variabili: bisogna cercare di capire cosa fa variare una variabile.

- Elementi del modello fattoriale di scomposizione della varianza:
 - o $VAR_{totale\ i} = comunalità + varianza\ specifica_i + e$
La variazione totale di "i", in cui "i" è la singola variabile presa in considerazione è dovuta a tre elementi sommati tra loro:
Comunalità = (indicata con h^2) contributo che potrebbe dare un fattore sconosciuto nella variazione di questa variabile.
Varianza specifica: si può pensare che una parte della variabilità sia dovuto ad un fattore sconosciuto, ovviamente una seconda parte della variabilità della stessa variabile è dovuta a sé stessa. Varianza specifica infatti è la varianza di una variabile.
E = errore che si può commettere, che è dovuto a vari fattori.
Normalmente non si è in grado di distinguere la seconda componente dalla terza, cioè la varianza specifica dall'errore; quindi, vanno necessariamente messe assieme e costituisce una cosa inestricabile e sono intimamente connesse. Posto ciò gli si può dare un nome unico, di "fattore unico/Unicità (U)".
L'equazione diventa quindi: $VAR_{totale\ i} = h^2 + U$

- La differenza tra analisi fattoriale ed analisi delle componenti principali si vede anche nel modo in cui queste due analisi trattano le due componenti dell'equazione, h^2 e U .
 - Nell'analisi fattoriale, nella diagonale della matrice, al posto delle autocorrelazioni (cioè, la correlazione di una variabile con sé stessa, che vale 1) viene messa una stima della comunaltà, cioè un valore che posso pensare assumi $l'h^2$.
Che valore si mette? È un valore che si può mettere con vari criteri:
 - Il valore che si sceglie di mettere corrisponde ad una tecnica diversa di analisi fattoriale: i vari tipi di analisi fattoriale si distinguono tra di loro per i valori che vanno a mettere nella diagonale della matrice.
 - Nell'analisi delle componenti principali questo problema non si pone perché non si tiene conto di U , e tutto viene spiegato dalla comunaltà.
 - Nell'analisi fattoriale sono incogniti il numero dei fattori comuni ed i valori delle comunaltà: dato che non c'è modo di conoscere questi valori si rendono necessari sia degli assunti da parte del ricercatore, quindi capire come stimare quei valori, sia delle particolari procedure di stima.
 - Ogni soluzione diversa che viene trovata per come si trovano i fattori e per come si stabiliscono i valori di comunaltà distinguono diversi tipi di analisi fattoriale.

Estrazione dei fattori, analisi fattoriale confermativa

Nell'analisi fattoriale il ricercatore parte dalle proprie conoscenze ed ipotesi pregresse relative ad un certo fenomeno grazie al quale ha un'idea precisa della struttura di relazione tra i fattori e le variabili. Può ipotizzare sia sul numero dei fattori e sui valori della comunaltà. L'analisi fattoriale in questo caso serve a valutare quanto il modello di relazione ipotizzato dal ricercatore sia compatibile/fitti con i dati goodness of fit/bontà dell'adattamento.

Quando invece non si è in grado di predisporre un modello sufficientemente specificato delle relazioni tra le variabili e i fattori, ci si rivolge alla tecnica dell'analisi fattoriale con funzione esplorativa.

Estrazione dei fattori, analisi fattoriale esplorativa

Bisogna fare ricordo a delle tecniche di scomposizione della varianza, che scompongono la parte h^2 dalla parte U :

- **Fattorializzazione principale/degli assi principali**, è la tecnica principale che viene utilizzata quando si fa analisi fattoriale esplorativa e non è discussa;
- **Minimi quadrati non ponderati (ULS o minres)**, in cui il ricercatore sceglie quanti fattori scegliere a priori;
- **Residui minimi generalizzati**;
- **Fattorializzazione alpha**, si basa sull'indice dell'alpha di ...;
- **Fattorializzazione immagine**;
- **Massima verosimiglianza (maximum likelihood - ML)**, per l'analisi fattoriale confermativa.

Nella maggior parte dei casi le differenze tra i risultati ottenuti sono trascurabili, almeno per i primi due fattori. Lo stesso dicasi per le differenze tra analisi fattoriale ed analisi delle componenti principali rispetto ai dati.

Estrazione dei fattori, analisi delle componenti principali

La componente, sinonimo di fattore, è una combinazione lineare e pesata di variabili.

$$Componente_i = w_{i1}X_1 + w_{i2}X_2 + \dots + w_{in}X_n$$

i = componente

Il primo peso della componente, il secondo peso della componente e il peso ennesimo della componente.

I pesi delle componenti vengono moltiplicate per le variabili che fanno parte di questa super-variabile.

X = variabili

La prima variabile, la seconda variabile, l'ennesima variabile che fanno parte della super-variabile.

I pesi indicano quanto pesa quell'indicatore sulla componente e sulla variabile: con che peso queste variabili contribuiscono a costruire il concetto assegnato alla componente.

w_{in} = pesi fattoriali

Non vi è nessuna separazione tra h_2 ed unicità U.

Le componenti sono estratte iterativamente in modo tale da riprodurre la maggior parte della varianza della matrice.

Le componenti non sono correlate tra loro, ortogonalità.

I fattori si devono pensare come se fossero delle dimensioni geometriche. I fattori tra di loro devono essere ortogonali.

24/10/2024

Interpretazione di fattori e componenti

Si estraggono dei fattori dalla matrice, ma come si interpretano?

Si guardano gli output del software quando si svolge l'analisi fattoriale o delle componenti principali.

La prima cosa che viene fuori facendo analisi fattoriale è una tabellina che comunica quanti fattori sono stati estratti, e dice anche quanto è potente/esplicativo il fattore, e quanta varianza è riuscito a spiegare/riprodurre. Vi sono fattori più o meno potenti nello spiegare una matrice, quelli più potenti sono quelli in grado di dire più cose sulla variabilità della matrice. Questo valore che dice quanto è potente il fattore/componente estratta si chiama autovalore (eigenvalue): equivale alla sua potenza e rilevanza esplicativa.

- Ogni autovalore spiega una certa percentuale di varianza;
- Più alta è la percentuale di varianza spiegata e più forte/esplicativo è questo fattore/componente trovata;
- Nell'analisi delle componenti principali, dividendo un autovalore per la somma degli autovalori, si ottiene la proporzione di varianza riprodotta da una componente.

All'interno di ciascun fattore/componente vi sono le variabili

I factor loadings, o pesi fattoriali/componenziali/saturazioni, quantificano la relazione lineare che esiste tra la variabile ed il fattore/componente.

Nella tabella si trovano le variabili, a cui appartengono dei valori che indicano in che misura quella variabile lì è correlata ad una relazione con la componente. Più alto è il valore che si trova, sia positivo che negativo, si nota che il fattore/componente è costituito da variabili che hanno valori più alti nella colonna di riferimento. Ora entra in gioco l'interpretazione del ricercatore che deve capire come quelle variabili stanno insieme, dovendo dare il nome al fattore/componente. Si possono ordinare questi valori in base alle dimensioni.

Jamovi ci permette di vedere i valori che superano una certa soglia, che può essere modificata.

La w_{i1} nell'equazione è il nostro factor loading.

I factor loadings saranno i responsabili della nostra interpretazione. Si vede come alcuni factor loading hanno valori positivi/negativi e in questa bivalenza può esprimere polarità.

Si può fissare il limite al di sotto del quale un peso è considerato irrilevante, valore soglia.

Alcune variabili possono essere escluse dall'analisi, e bisogna però ricominciare daccapo. (Jamovi lo fa automaticamente)

Queste saturazioni saranno sempre più alte nella prima componente e più basse nella seconda, e così via, si sarà più esigenti nella prima componente e gradualmente si sarà meno esigenti. Si dice "dovrebbe" a meno che non ci siano delle cose straordinarie.

Il ricercatore a questo punto partendo dai factor loadings cerca di attribuire un nome al fattore/componente: ragionamenti che si fanno confrontandosi con altri ricercatori.

Scelta del numero di fattori/componenti

Si deve trovare un compromesso tra quantità di varianza spiegata e semplicità del modello, quanta varianza si riesce a spiegare ed il mantenere il modello semplice ed elegante. Si deve trovare la strategia/regola adatta per scegliere il numero più appropriato di fattori:

1. Regola dell'autovalore maggiore di 1
Si prendono i valori eigenvalue >1: si chiama Criterio di Kaiser (Kaiser Criterion)
2. Scree test/Scree plot
È un test della ghiaia che si fa attraverso il grafico dello scree plot.
Si prendono gli eigenvalue e nel grafico si forma un "avvallamento" (su Jamovi si controlla su "additional value").
Il valore $y=1$ è il criterio di Kaiser.
Il test afferma di guardare l'asse delle x in cui vi sono tutte le componenti.
Nello Scree test si guarda la pendenza tra i vari componenti, nel momento in cui la curva si raddrizza ci si ferma.
3. Varianza totale riprodotta dall'insieme dei fattori scelti
Darsi un livello di varianza che si vuole raggiungere.
4. Ispezione della matrice dei residui
Non si usa molto, si cerca di capire quanto errore viene riprodotto quando si utilizza un fattore/componente in più.
5. Analisi parallela
Non si usa molto, consiste nel trovare attraverso un algoritmo una linea che taglia lo scree plot e fa vedere la soglia critica sopra la quale si possono accettare le componenti e sotto la quale queste componenti non si possono accettare.

Queste strategie si possono combinare/unire tra di loro.

Nella pratica difficilmente si superano i $\frac{3}{4}$ fattori, normalmente si prendono solo 2 fattori.

Rotazione dei fattori

- Spazio fattoriale

È lo spazio che viene disegnato quando vengono proiettate le variabili che hanno fatto parte dell'analisi utilizzando delle coordinate che sono i factor loadings.

Ogni variabile, avendo il proprio factor loading, potrebbe essere disegnata in un sistema di asse cartesiani.

Si chiama spazio fattoriale perché gli assi che creano questo grafico sono gli assi cartesiani, si può così vedere che posto occupano nei vari quadranti e si può dedurre che i punti vicini sono vicini perché correlati ed hanno delle caratteristiche simili in base alle componenti.

Se si devono impacchettare delle variabili significa che le variabili devono stare in quel pacchetto e non in diversi pacchetti. È favorevole quando una variabile sta sopra un asse in quanto avrà valori alti di x e valori di y pari a 0, o viceversa quando si ha una variabile con valori alti di y e valori di x pari a 0.

Si parla di rotazione dei fattori in quanto si fanno girare gli assi cartesiani x e y in modo tale da fare combaciare gli assi con i valori dei fattori: se corrispondono, a questo punto i valori della x e della y saranno esclusivi per qualsiasi variabile. Ciò rende più leggibile tutto, attraverso la trasformazione geometrica ed ottenere delle variabili discriminanti rispetto un asse rispetto all'altro. L'obiettivo è quello di riuscire ad avere, nella tabella dei factor loadings i valori in una sola tabella e non in entrambe.

I factor loadings sono usati come coordinate delle variabili in analisi.

- Sulla x si pone il fattore estratto per primo, sulla y quello estratto dopo.
- Gli assi fattoriali si ruotano geometricamente per ottenere gli spazi fattoriali che spiegano meglio il senso dei fattori affinché siano compatti ed univoci:
 - La rotazione degli assi deve tendere a concentrare i factor loadings di ciascuna variabile su un solo fattore/componente
- Rotazione può essere manuale o per algoritmi:
 - Manuale: si guarda il grafico, e si fanno girare gli assi finché non si sovrappongono sui punti; si può fare quando vi è una configurazione adeguata al lavoro che si fa. Questa configurazione espone ad una certa arbitrarietà in modo tale da affidarsi ad approssimazioni;
 - Algoritmi:
 - Algoritmo ortogonale: gli assi si possono muovere tendendoli fermi/fissi.
 - Varimax, la più utilizzata
Se la varimax trova dei valori che sono ancora doppi si prova con gli altri algoritmi finché non si trovano le singolarità.
 - Quartimax
 - Equamax
 - Algoritmo obliquo: consente di muovere gli assi in maniera indipendente i punti.
 - Promax
 - Direct oblimin

Nell'analisi fattoriale le componenti possono essere diverse in quanto vi è l'unicità dei fattori.

Controlli post-hoc

Nell'analisi fattoriale si partiva dalla matrice di correlazione, da cui si partiva da un valore di 0.5

Esistono dei test:

- Test di Kaiser-Meyer-Olkin (KMO)

Ci permette di capire delle cose sulla matrice che viene utilizzata.

Su questo test si verificherebbe un problema. Nei software si trova spiegato il KMO come test che dovrebbe misurare l'adeguatezza campionaria.

Nel 1970 Kaiser aveva scritto un articolo che cercava di studiare la matrice valutando anche l'adeguatezza campionaria di cui si parla, e fornisce una formula per valutare l'adeguatezza campionaria.

Nel 1974, quattro anni più tardi, ritorna su questo articolo rivedendo ciò che aveva detto e pone delle correzioni, cercando di non misurare più l'adeguatezza campionaria ma la varianza dei fattori riconosciuti.

Nei software accade che si utilizza la formula più recente, affermando che misura l'adeguatezza campionaria. È ambiguo poiché nell'articolo più recente viene chiamata con un altro nome, MSA.

In realtà misura la percentuale di varianza spiegata verosimilmente da fattori sottostanti.

Vi è un'altra ambiguità:

- >0.90 eccellente
- 0.8-0.9 buono
- 0.7-0.8 accettabile
- 0.6-0.7 mediocre
- 0.5-0.6 scarso
- < 0.5 inaccettabile

(valori che si trovano nell'articolo scritto da Kaiser nel 1974)

I valori più alti sono quelli migliori e da tenere in considerazione, quelli più bassi affermano che determinate variabili si possono escludere/non considerare.

29/10/2024

Si controlla se la matrice di correlazione è sufficientemente articolata per effettuare l'analisi fattoriale.

- Test di sfericità (della matrice di correlazione) di Bartlett

Sfericità, è una nozione complessa dal punto di vista matematico.

Il test prova a definire un'ipotesi nulla, in cui le variabili utilizzate sono completamente indipendenti, cioè che non vi è nessuna correlazione tra di loro. Man mano che ci si allontana dalla nullità si ha qualcosa, e questo qualcosa sarebbero i fattori nel test di Bartlett.

Si fa l'ipotesi che non vi sia relazione tra le variabili e che non ci siano quindi nemmeno fattori, e poi si cerca di vedere con una misura chi-quadrato e con il valore di "p" se si è lontani o vicini a questo nulla: se p è basso ($p > 0.05$) allora nella matrice vi è abbastanza correlazione per effettuare un'analisi fattoriale.

Punteggi fattoriali

Passaggio cruciale della procedura è quello dell'attribuzione dei punteggi fattoriali di ogni singola persona, secondo l'esempio svolto su liberali e chi manca di senso civico (european values study).

- Punteggi fattoriali, factor scores, sono relativi ad ogni unità d'analisi.
Danno una misura di quanto ciascuno possiede della super-variabile ottenuta
La costruzione/l'individuazione dei punteggi fattoriali nel caso dell'analisi delle componenti principali non comporta nessuno tipo di problema in quanto vi è un solo modo per calcolare questi factor scores.

Quando si fa l'analisi fattoriale vi sono diverse tecniche utilizzate per calcolare i punteggi, i factor scores:

- **Thurstone**, più diffusa, si basa sulla regressione, consente di ottenere i punteggi già standardizzati;
- **Barlett**, una correzione del precedente;
- **Anderson-Rubin**, un'estensione della tecnica di Bartlett, secondo la quale i factor scores non li rende correlati tra di loro;
- Ten Berge, versione obliqua dell'estensione precedente;
- Harman, basata sul principio del idealized variable estimator;

Tecniche che restituiscono dei punteggi che restituiscono i punteggi fattoriali.

Component scores chiamati perché si fa l'analisi delle componenti principali.

Factor score chiamati perché si fa l'analisi fattoriale.

Si hanno due nuove variabili e dei punteggi che sono i punteggi di ogni componente del campione, se è vuoto è perché ci sono dei missing values, valori mancanti. Sorge da qui la curiosità sul fare un'analisi mono-variata di ogni singola variabile per vedere come queste si distribuiscono.

Possono essere aggiunti alla matrice dati originaria, costituendo delle nuove variabili per analisi successive:

- Se abbiamo intenzione di utilizzare in analisi successive i nostri fattori sarà meglio usare l'analisi delle componenti principali in quanto non vi è margine di arbitrarietà sulla costruzione/misurazione/calcolo di punteggi fattoriali.

L'analisi delle componenti principali può essere usata per ponderare gli indicatori di una scala/indice.

Quando si costruisce una scala vi è una ponderazione, far valere di più certe variabili e far valere di meno altre variabili. Ognuno degli indicatori non ha lo stesso valore, vi possono essere valori più o meno importanti. Si possono trovare dei pesi da attribuire alle variabili così da dare un ordine alla scala ma vi è il problema dell'arbitrarietà ed il motivo per cui si attribuiscono determinati pesi a determinate variabili: si è quindi esposti alle critiche. Per risolvere la questione di arbitrarietà si può far calcolare i pesi degli indicatori ad un'analisi fattoriale.

Si estrae una componente del paniere di variabili coi relativi pesi fattoriali:

- Si standardizzano i valori di ciascun caso: $Z_i = \frac{(X-M)}{\text{deviazione standard}}$

- $Indice = z_1 * coefficiente\ variabile_1 + z_2 * coefficiente\ variabile_2 + \dots + z_n * coefficiente\ variabile_n$

Z è la variabile di riferimento.

Coefficiente variazione è il peso della variabile.

Standardizzazione, intanto si calcola la media della distribuzione per poi effettuare

$$\frac{l'equazione: standardizzazione_{variabile\ di\ riferimento} = \frac{\text{valore di riferimento trovato nella distribuzione} - \text{valore medio}}{\text{deviazione standard}}}{SD (deviazione standard)} = \frac{x_i - \bar{x}}{SD (deviazione standard)}$$

Analisi fattoriale confermativa

Si parte dal modello costruito per poi averne conferma della validità.

Si deve definire il modello: scegliere variabili per ogni fattore ipotizzato possano caratterizzare la matrice. Quando si costruisce un modello, si utilizza la stima di comunaltà, h^2 , ma nell'analisi fattoriale confermativa si deve fare riferimento alla Maximum Likelihood estimation (ML estimation).

Tutti i fattori devono essere specificati.

Vi è un trattamento dei missing values in quanto il modello non tollera le mancate risposte.

Constraints (identificazione), se si vogliono mettere dei vincoli di natura statistica nel modello, uno dei vincoli inevitabili è il numero di variabili che devono essere almeno 3; gli altri vincoli sono:

1. Variance standardization method
2. Marker method

La questione è se si vuole o meno che ci siano nel modello o nel fattore delle variabili che facciano da riferimento per le altre, utilizzate per scalare i valori delle altre. L'indicatore di riferimento normalmente è il primo che viene selezionato.

Si deve stabilire la scala di misura del fattore latente, o è la varianza o è il fattore.

Stime del modello: assomiglia a qualcosa di analogo alla "b" nei modelli di regressione lineare multipla, cioè di quanto aumenta y all'aumentare di una unità della x. Ci sono dei valori più alti e più bassi che rappresentano l'importanza della variabile, per superare questo problema si devono standardizzare le variabili.

- Covarianza tra fattori,
- Test statistics: coefficienti di regressione (variabile-fattore) equivalgono alle stime, valore test, p-value, beta (correlazione variabile-fattore) equivale a b standardizzato

Il modello che è stato creato deve essere confermato e può accadere che questo non funzioni, si deve controllare quanto fitta e controllare quindi l'indicatore di fitness attraverso il chi-quadro che dice in che misura la costruzione reale è lontana da quella che si è costruita, nel caso dell'analisi confermativa funziona al contrario in quanto l'ipotesi nulla significa che più ci si allontana dal modello perfetto più significativa è la stima.

Misure di goodness of fit:

- Chi-quadrato, si legge al contrario misurando la distanza dall'ipotesi di fit perfetto;
- Comparative Fit Index, CFI, ha una soglia per la quale il risultato deve essere >0.90 o >0.95;
- Tucker-Lewis Index, TLI, ha una soglia per la quale il risultato deve essere >0.90;

- Root Mean Square Error of Approximation, RMSEA, che deve essere il più piccolo possibile in quanto è una misura di errore; ha dei margini:
 - 0.01 eccellente;
 - 0.05 buono;
 - 0.08/0.1 mediocre.

Se non vengono rispettate queste misure il modello deve essere modificato, e può essere modificato manualmente o tramite algoritmo:

- Additional output:
 - Residui correlazioni osservate/attese- Modification indices (togli valori più alti) – Plot

Si può vedere il Path diagram tramite il quale si vede il grafico del lavoro svolto e quali sono le variabili prese in riferimento secondo ciò che è stato costruito: equivale al lavoro svolto ma in forma grafica.

La cosa che si può osservare è la correlazione con gli errori/residui, cioè quanto ogni indicatore è correlato con gli errori: più si hanno valori alti ci si trova in una situazione non ottimale (indicati con il colore rosso su Jamovi).

L'output migliore per aggiustare il modello è "Modification indices" grazie al quale il sistema consiglia quali variabili si possono togliere dai fattori per migliorare il modello. La matrice che si crea indica dei valori in nero o in rosso, in cui quelli rossi indicano le variabili che devono essere eliminate.

SCALE D'ATTEGGIAMENTO

Definizione: una scala è un insieme coerente di item/elementi, che corrispondono alle domande dei questionari, che servono a misurare un concetto più generale o un atteggiamento non direttamente osservabile (tratti, costrutti, variabili latenti ecc.).

Coerente significa che tutti gli elementi che vengono scelti, e che vengono utilizzati per costruire la scala devono servire per fare la stessa cosa.

Un atteggiamento è un giudizio permanente, sia positivo o sia negativo, riguardo persone, idee, oggetti. Questi sono composti da tre componenti:

1. Componente emotiva: accompagna il giudizio che è partito dalle emozioni nei confronti di persone, idee o oggetti (es. paura, disgusto, piacere, tristezza);
2. Componente cognitiva: ha a che fare con i ragionamenti, delle considerazioni su ciò che succede o si vede, nei confronti di persone, idee o oggetti;
3. Componente comportamentale: quello che si fa, come ci si comporta per effetto dell'atteggiamento che si ha.

L'opinione è una espressione verbale dell'atteggiamento. È interessante in quanto si può chiedere, ed analizzando l'espressione verbale si può risalire all'atteggiamento.

Sviluppo dello scaling:

- Proposte principali:
 - Thurstone (1927);
 - Likert (1932) che aggiusta le proposte di Thurstone;

- Guttman (1944) introduce delle novità pensando che si possono misurare gli atteggiamenti attraverso domande dicotomiche (si/no);
 - Rasch (1960) è riuscito a rendere sofisticata la tecnica facendo ricorso a modelli matematici probabilistici.
 - Applicazioni:
 - Servono a misurare stati emotivi (es. ansia, depressione, risentimento, ecc.);
 - Tratti psicologici (es. autostima, introversione, ecc.):
 - I big five: apertura mentale, coscienziosità, estroversione, amicalità, stabilità emotiva
Ognuno di questi cinque tratti si divide in due sotto-tratti; si utilizzano tantissimo nella selezione del personale
 - Bisogni (es. autorealizzazione, potere, carisma, ecc.);
 - Relazioni sociali (es. status sociale, integrazione familiare o integrazione sociale, ecc.);
 - Orientamenti politici (es. sinistra-destra, conservatorismo, partecipazione politica, ecc.);
 - Abilità e capacità manuali e mentali (es. intelligenza), grado di apprendimento.
 - Aspetti tecnici: per vedere come fare il lavoro di misurazione degli atteggiamenti
 - Formato delle domande (item), come si formano:
 - Si fa ricorso a domande con risposte a parziale autonomia semantica, cioè domande che prevedono delle risposte che sono fra di loro graduate (molto, abbastanza, poco, per nulla).
Per far ciò bisogna che l'intervistato/a conosca tutte le altre opzioni di risposta. Queste non sono direttamente la risposta, ma il problema si verifica in quanto normalmente si etichettano con dei numeri perché si tratta di variabili ordinanti: si possono utilizzare queste domande per fare le stesse cose che si possono fare con le variabili cardinali?
Soluzione:
 - Scale auto-ancoranti, cioè domande in cui si cerca di chiedere da 1-10 quanto si è convinti ecc. da questa cosa?
Se si chiede da 1-10 quanto ... si è trasformata la natura di ciò che viene raccolto in quanto nelle persone questa scala si avvicina alla modalità delle domande cardinali; si fanno delle operazioni matematiche e si possono quindi utilizzare tecniche di natura quantitativa.
 - Non si può affermare che le modalità siano equidistanti tra di loro, ma se per interpretare la risposta, l'intervistato/a fa riferimento alla matematica, ed alla possibilità di fare calcoli, soprattutto quando le alternative sono tante, allora quel trattamento si può fare: è probabile quindi che ricorra ad un meccanismo di comparazione quantitativa, specie se le alternative sono numerose.
- Si presenta un altro problema, cioè quante modalità di risposte possono avere queste scale?
- Likert nella sua formulazione originaria ne aveva previsto 7, che agevola le operazioni matematiche;
 - Le modalità di risposta si ridussero a 5, poi a 4, poi a 3;
 - Guttman proponeva delle modalità di domanda dicotomiche, a 2 risposte.

Quante alternative si devono mettere? Il numero giusto, cioè, trovare un equilibrio tra tante modalità e troppo poche. Si che all'aumentare delle alternative il trattamento quantitativo è più plausibile, ma il problema è che quando si trovano troppe alternative di risposta aumenta la difficoltà di risposta ed aumenta uno sforzo cognitivo elevato per l'intervistato/a.

- Trade-off, compromesso;
- Si è presentato un altro problema riguardo al numero pari o dispari di opportunità di risposta: nel numero dispari si può mettere un valore centrale neutro. Si mette sempre un valore centrale a meno che non si voglia esplicitamente forzare l'intervistato/a ad una scelta (si fa quando il questionario riguarda politica, religione o questioni etiche, in generale risposte molto precise).
Raccomandabile è mettere l'opzione "non saprei" che risolve il problema della possibilità di imbarazzo rispetto delle domande troppo invadenti ed evitare pseudo-opzioni.
- Le scale producono alla fine variabili quasi cardinali
Mettendo insieme tutte le risposte, alla fine si ottengono le variabili quasi cardinali, che sono sottoponibili alle tecniche quantitative.
 - Alcuni modelli statistici di matrice probabilistica riescono a realizzare l'eguaglianza tra intervalli propria delle misurazioni, secondo il modello di Rasch

SCALE LIKERT

Sono delle scale additive, cioè in cui si sommano tutti i punteggi associati ad ogni item. Vengono proposte una serie di affermazioni sulle quali esprimere accordo/disaccordo (5/4 modalità di risposta, originariamente 7 modalità di risposta).

- Fasi di realizzazione:

- Formulazione delle domande, seguendo un approccio teorico deduttivo si pensa quali potrebbero essere gli indicatori che servono a misurare quel qualcosa/quel concetto. Si devono trovare tutti i possibili indicatori che permettano un'adeguata risposta.
- Somministrazione delle domande, ad un campione di persone/individui e successivamente si devono fare dei controlli.
Quando si somministrano le domande? Vi possono essere delle distorsioni tra intervistatore ed intervistato: si possono porre in essere una serie di comportamenti che distorcono il dato:
 - Desiderabilità sociale (quando si ha a che fare con degli estranei l'individuo mostra la parte migliore di sé);
 - Response set (dare le stesse risposte a tutte le domande);
 - Pseudo-opinioni (che si fanno sul momento per accontentare l'intervistatore).
 - Fonti di distorsione: contenuto (cosa viene chiesto), struttura (quando viene chiesto), setting (dove viene chiesto), intervistatore (chi pone le domande)

Si costruiscono scale di desiderabilità per poter spiegare queste distorsioni.

- Controlli di validità, attendibilità ed unidimensionalità (item analysis): solo dopo aver superato questi controlli la scala è una scala Likert, in caso contrario è una scala “stile Likert”

- Validità e attendibilità:

Quando si misura un concetto/costrutto:

- $X = \text{valore reale} + \text{bias (errore non dovuto al caso)} + \text{errore}$
- Validità è la misura in cui ciò che abbiamo misurato corrisponde con ciò che volevamo misurare.
 - Validità di contenuto, in cui ci si chiede se gli item/indicatori sono adeguati a misurare ciò che si vuole misurare;
 - Validità convergente, convergent validity, significa che, se esistono già degli altri test validati nella letteratura, in che misura questa scala appena misurata corrisponde con quelle già esistenti, si vede appunto se sono simili o meno;
 - Validità divergente, divergent validity, si vede se esistono delle scale che misurano cose contrarie alla scala appena misurata, quindi, si controlla quanto e se sono diverse;
 - Validità nomologica, ha a che fare con le teorie generali, si vede se la scala appena misurata produce dei risultati che sono coerenti con una letteratura di cui si è già a conoscenza.

Si misura tutto insieme per controllare la validità.

- Attendibilità, reliability, riguarda la ripetibilità, la stabilità e la coerenza delle misurazioni.

Si può valutare come correlazione tra due somministrazioni secondo il principio del:

- Test-retest, secondo cui si fa un primo test ed un secondo test in cui si devono ottenere gli stessi risultati del primo: si calcola quindi la correlazione tra due somministrazioni, ma non fa emergere il bias;
- Parallel test, si usano strumenti diversi ma simili, fa emergere il bias;
- Coerenza interna, inter-item reliability, cioè che si cerca la coerenza all'interno dello stesso strumento in cui si fanno una serie di misurazioni: si cerca di capire se ogni item della scala va nella stessa direzione di misurazione della scala complessiva
 - Split-half, correlazione elemento-scala, tramite l'Alpha di Cronbach (calcolare un numero unico il quale dice se si è costruita una scala buona/brutta) che ha un valore soglia minimo di 0.70 ed aumenta all'aumentare dell'item; e l'Omega di McDonald

- Unidimensionalità

È un controllo che si fa per misurare una ed una sola cosa quando si costruisce una scala. Quello che si può cercare di capire è se all'interno della scala esistono più dimensioni e si effettua tramite l'analisi fattoriale.

- Esiste una scala psicosociale chiamata “scala di need-for-affect” ideata da Maio ed Esses che comprende 26 item e misura il sentire/la sensibilità ovvero quanto le emozioni agiscono sugli individui/la necessità o il bisogno di provare o non provare.
- Il dataset, n=926;
- Item analysis e analisi fattoriale, con la prima analisi si può vedere se la scala ha una Alpha di Cronbach adeguata; con la seconda analisi invece si vede, tramite l'ACP, successivamente alla quale bisogna chiedersi quali sono le variabili caratteristiche della prima componente (con i punteggi fattoriali più alti);

Usare i factor scores come punteggi di nuove scale.

SCALING MULTIDIMENSIONALE (MDS)

È un approccio diverso, è più statistico/computazionale, perché si tratta di estrarre delle dimensioni concettuali da un insieme di dati che riguardano i casi ed in modo da tirar fuori le variabili latenti, che contribuiscono alla rappresentazione di un fenomeno all'insaputa del ricercatore.

Invece di partire dalla teoria per trovare gli indicatori, si svolge il procedimento opposto partendo dagli indicatori.

- Tecnica di riduzione dei dati, come l'analisi fattoriale

Dal punto di vista computazionale stretto vi è una differenza dall'analisi fattoriale, che partiva da una matrice di correlazione, mentre la MDS parte da una matrice di distanze tra le coppie di oggetti presi in considerazione per l'analisi.

La distanza si calcola tramite il grafico degli assi cartesiani, la distanza tra un punto e l'altro si calcola tramite il Teorema di Pitagora poiché la distanza equivale all'ipotenusa: $C_1^2 + C_2^2$, se si vuole calcolare esattamente la misura si deve fare: $\sqrt{C_1^2 + C_2^2}$

A partire dalla matrice delle distanze si riesce a ricostruire la mappa del mondo, nel caso delle ricerche scientifiche si trovano le mappe delle persone nello spazio di riferimento.

12/11/2024

Lo scaling multidimensionale (MDS):

- Estrarre delle dimensioni concettuali da un insieme di dati che riguardano i casi;
- Tecnica di riduzione dei dati, importante quando vi sono tante variabili.

Per effettuare uno scaling multidimensionale, invece di considerare una matrice di correlazione, si considera una matrice di distanze/dissimilarità tra le coppie di oggetti/casi. Si tratta di una matrice quadrata dentro la cui celle vi sono le distanze, che vengono generalmente calcolate tramite le distanze euclidee (ipotenusa di un triangolo rettangolo di cui si conoscono i due cateti, si calcola tramite il teorema di pitagora).

Vi possono essere più di due variabili, dipende dalla matrice a cui si fa riferimento: non cambia nulla si svolge ugualmente il teorema di pitagora, pur se diventa un iperspazio. Questa formula viene corretta dividendo tutto per il numero di variabili, perché le distanze possono essere iper-stimate.

Partendo da una matrice delle distanze si può pensare a una rappresentazione di “n” oggetti in uno spazio a “k” dimensioni, cioè che ognuno di questi casi potrebbero essere ricollocati in uno spazio a “k” dimensioni (che alla fine sono due dimensioni).

Procedura stilizzata:

- Calcolare la matrice delle distanze;
- Capire matematicamente se lo spazio comune esiste;
- Stabilire quante dimensioni possiede;
- Collocare ogni caso nello spazio, posizionarle in questo spazio che si è costruito;
- Dare un nome a tali dimensioni.

Lo fa automaticamente Jamovi tramite il plug-in “snow cluster” e “multidimensional scaling plot”. Vi possono essere valori sia positivi che negativi. Si deve vedere se di queste si può fare un clustering, cioè un raggruppamento delle variabili per somiglianze statistiche, e si fa tramite “k-means plot”.

Per aiutarci a dare un nome alle dimensioni ci serviamo dell’analisi fattoriale, nello specifico dell’analisi delle componenti principali. Ci si può chiedere come sono posizionate le variabili nel PCA plot. Generalmente si vede tramite un biplot, valutare se si deve effettuare una rotazione degli assi.

ESPERIMENTI ONLINE E OFFLINE

Argomento che è stato per diverso tempo controverso in quanto in sociologia condurre un esperimento significa influenzare i comportamenti delle persone. Dipende dai contesti di ricerca.



Si comincia da una differenza tra:

- Studi osservazionali:
 - o Variabili quasi-indipendenti, non si tratta di variabili indipendenti in quanto il ricercatore non può modificare le variabili a suo piacimento senza poter fare delle manipolazioni sulla x per vedere come cambia la y; abbiamo avuto a che fare con delle variabili quasi-indipendenti che continuano a non essere manipolabili ma si fa un passo indietro manipolando/cambiando i soggetti di ricerca.
 - o Modelli correlazionali, di conseguenza si misura anche la “p” perché vediamo anche se sia significativa o dovuta al caso. Più grande è il campione, più vicini ci si trova vicini alla realtà.
 - o Correlation does not imply causation: cioè, le correlazioni che vengono misurate non corrispondevano necessariamente ad una causa. Non si possono mai studiare le cause dei fenomeni;
 - o Variabili confondenti (confounds): camuffano la relazione che esiste tra x e y.
 - Studi sperimentali:
 - o Variabili manipolabili;
 - o È importante se le differenze che si colgono tra i dati sono significative e degne di nota, non si misura quindi la correlazione e la “p”; invece di guardare alle correlazioni si guardano alle differenze. I campioni possono essere molto piccoli,
 - o Si può affrontare il problema della ricerca della causa in quanto si possono studiare le cause dei fenomeni.
 - o Si cerca di dare una risposta a queste domande.
- ⇒ Negli studi sperimentali ci si chiede **perché** succedono le cose, cosa causa cosa;
- ⇒ Si tratta di **vere variabili indipendenti** che si possono manipolare/stimoli che possono essere di varia natura;
- ⇒ Si possono **identificare e misurare i nessi di causalità**

- Si possono anche fare delle previsioni e delle prevenzioni
- ⇒ Variabili confondenti, confounds, che sono sotto controllo in modo tale che non diano fastidio.

Tipi di esperimento

- Esperimenti perturba e osserva, disegni within groups o repeated measures:
 - Sono esperimenti entro soggetti, in cui si interviene su un solo gruppo e poi si misura il risultato; vi è un solo gruppo
 - Problema dei possibili confondenti;
- Esperimenti controllati randomizzati, disegni between groups:
 - Sono esperimenti tra soggetti;
 - Si interviene su alcune persone e non su altre, vi sono almeno due gruppi, assegnando a caso chi apparterrà al primo gruppo e chi al secondo, le persone saranno simili in ogni gruppo;
 - La scelta randomizzata garantisce il controllo delle variabili confondenti: è un modello che risolve questo problema delle confondenti;
 - Il gruppo di controllo è quello a cui non viene somministrato alcun stimolo per vedere se la manipolazione nell'altro gruppo ha prodotto alcun effetto;
- Esistono delle combinazioni: esistono disegni semplici, misti: within-between e fattoriali (con due o più variabili e due o più modalità)



Con fattoriale si intende che vi sono delle variabili/dei fattori, ciascuna di queste variabili può avere due o più modalità e si indicano con il numero di modalità della prima variabile moltiplicato al numero di modalità della seconda variabile, ed eventualmente moltiplicato al numero di modalità della terza variabile e non oltre perché può essere complicato

- Reattività e bias: modalità single o double blind
Reazione che viene fuori quando si entra in contatto con il contesto dell'esperimento, avviene una bias, una distorsione.

- Single blind: una cosa che si può fare è “accecare” la persona che viene posta ad esperimento, in quanto non deve sapere a che tipo di esperimento sta partecipando e non deve sapere se ha ricevuto o meno il trattamento.
- Double blind: si può “accecare” sia la persona destinataria sia il ricercatore in quanto non devono sapere che tipo di esperimento sta partecipando e non deve sapere se ha ricevuto o meno il trattamento e contemporaneamente il ricercatore non sa che tipo di trattamento sta esponendo ed a chi.
- Setting:
 - Esperimenti in laboratorio: molto controllo ma poco realistici ed il problema è il cercare di disattivare la distorsione dei soggetti WEIRD (western, educated, industrialised, rich and democratic), cioè, che fanno parte di una categoria di questo acronimo.
 - Esperimenti sul campo: più realistici ma con meno controllo;
 - Esperimenti digitali/online: sono realistici e controllati, combinano i vantaggi degli esperimenti in laboratorio e degli esperimenti sul campo.

14/11/2024

FARE ESPERIMENTI ONLINE

Modi:

1. Farsi aiutare da società che fanno queste cose, che conducono esperimenti online, o farsi aiutare da aziende che consentono di condurre determinati esperimenti.
 - a. Vincoli aziendali, interessi diversi che possono far sì che si entri in conflitto;
 - i. Ricerca applicata
 - ii. Ricerca di base
2. Individualmente, vi è maggior controllo;
 - a. Sistemi esistenti, vengono utilizzate determinate piattaforme che sono pensate esplicitamente per svolgere determinati esperimenti;
 - i. Vincoli di natura tecnologica, potrebbero opporre ostacoli nella conduzione dell'esperimento
 - b. Costruzione ad hoc
 - i. Svantaggi: progettazione, reclutamento e costi;
 - ii. Risorse: Amazon che ha inventato una piattaforma
 - c. Costruzione di un sistema
 - i. Come creare una start-up: alti rischi quanti alti ritorni nel caso in cui questa vada in porto.

Bilancio metodologico:

- Vantaggi, in generale degli esperimenti online:
 - Controllo: si possono avere delle informazioni pretrattamento;
 - Realismo: i contesti sono più naturali, vi è una bassa intrusività ed i partecipanti sono più eterogenei;
 - Disegni più sperimentali;
 - Scala, maggiore robustezza statistica nei disegni fattoriali;
 - Dimensione longitudinale: dati di processo always on;
 - Risorse online, Amazon Mechanical Turk.

- Svantaggi:
 - o Costi;
 - o Compliance, grado di collaborazione;
 - o Dipendenza dall'ambiente tecnologico, affordances, cioè le cose che si possono/non possono fare in un ambiente online;
 - o Questioni etiche.

Fasi di un esperimento:

1. Ideazione e progettazione;
2. Reclutamento:
 - a. Quante persone servono per svolgere questo esperimento;
 - b. Quali persone.
3. Randomizzazione, che può esserci o non esserci in base al tipo di esperimento;
4. Trattamento, che consiste nella somministrazione di uno/più stimoli;
5. Misurazione dell'effetto e analisi.

Valutare i risultati di un esperimento:

- T-test, o chiamato anche test di Student, pseudonimo di un ricercatore che faceva degli studi sperimentali sulle birre;

Serve a dare una risposta alla domanda “”, non si fanno più esperimenti di tipo correlazionale ma interessa capire se la differenza tra uno stimolo ed un altro ha un peso, ed in generale si fanno differenze tra medie: serve a comparare due medie:

- o Single sample, confronto fra la media di un campione e la media della popolazione, senza essere a conoscenza dello Standard Deviation, deviazione standard;

$$t = \frac{M - \mu}{SE_M}$$

μ = valore teorico

df = degrees of freedom = n - 1

p va calcolato in base all'opzione teorica d'interesse

$$d = \frac{M - \mu}{SD}$$

0.2 small

0.5 medium

0.8 large

1.2 very large

>2 huge

- o Dependent T-test, confronto delle medie tra le stesse persone in due condizioni diverse, pre-post;

$$t = \frac{M_D - \mu}{SE_{MD}}$$

M_D è la media delle differenze

$$d = \frac{M_D - \mu}{SD_{MD}}$$

- o Independent T-test, confronto delle medie tra gruppi diversi, chi ha ricevuto il trattamento e chi no.

$$t = \frac{M_1 - M_2}{SE_{differenze}}$$

$$df = (n_1 - 1) + (n_2 - 2)$$

le media dei due gruppi vengono ponderate in base a n

$$d = \frac{M_1 - M_2}{SE}$$

I test di significatività, controllare se la relazione o il t-test è dovuto al caso o meno, sono l'espressione di un rapporto tra valori osservati e attesi:

- $T = \frac{\text{media osservata} - \text{media attesa}}{SE}$ SE= standard error, deviazione standard / radice quadrata di n
- La distribuzione di t varia in base ai gradi di libertà, si presenta in vari modi in base ai gradi di libertà, i quali dipendono dal numero di persone coinvolte nella ricerca. In base a quanto è grande n, la distribuzione tipica di t varia.
- Il valore del t-test va accompagnato dalla significatività (p) e dalla dimensione dell'effetto (effect size: Cohen's d)
Si cerca la misura della dimensione dell'effetto che si misura con il coefficiente che si chiama d di Cohen.

Esperimento con più di due condizioni: ANOVA

- ANOVA, analysis of variance, ad una via (one way):
 - Una variabile indipendente, one way, con più di due categorie;
 - Una variabile dipendente che è una variabile cardinale.

Si possono avere due tipi di disegno:

1. Within groups, repeated measures;

- Vantaggi:
 - Più economica, in quanto ogni soggetto è sottoposto a tutti gli stimoli;
 - Ha una maggiore potere statistico in quanto non si hanno più gruppi; quindi, non si ha il problema della variabilità, la varianza, nelle k prove, quindi è sistematica, cioè, dovuta allo stimolo
- Svantaggi:
 - Ordine delle condizioni, order effect, che è essenziale in quando cambiando l'ordine cambia il risultato. Si può controbilanciare:
 - Blocked design: si possono considerare tutte le combinazioni di stimoli che però sono di ordine k! (fattoriale);
 - Randomized design: è casuale ma dà dei problemi in quanto non è pratico;
 - Latin squares: ogni condizione appare in ogni posizione almeno una volta
 - Missing data
 - Si deve capire quante celle mancano, normalmente non si deve superare il 10% ma in generale meglio che non manchino;
 - Si deve capire se i dati mancanti seguono uno schema;
 - Soluzioni:
 - Eliminazione dei casi;
 - Stimare i valori mancanti tramite il calcolo della media;

- Far prevedere i valori tramite la regressione.
- Parametri:
 - F di Fisher, che calcola la varianza sistematica, dovuta all'intervento della variabile, e che calcola la varianza non sistematica (random) dovuta al non intervento della variabile.
Test di significatività che calcola la varianza sistematica paragonata alla varianza non sistematica.

Fa parte della famiglia di distribuzioni che dipendono da n, quanto è grande il campione.
 - Vi è un p level, che in base alla grandezza di n afferma quanto la F sia dovuta al caso, deve avere un valore < 0.5
 - Effect size, che cambia nome e viene chiamato eta-quadrato η^2 , che misura la forza della relazione, cioè quanta varianza viene calcolata dal modello, si tratta di un numero $0 < \text{effect size} < 1$ (compreso tra 0 ed 1) più è vicino ad 1 più è forte, più è lontano da 1 più è debole.

19/11/2024

Si deve ricostruire la variabile indipendente, in quanto su Jamovi viene divisa in variabili. In "level 1/2/3" si inseriscono le modalità delle variabili.

- Presupposti:
 - Assumption di sfericità, ci si chiede se la varianza è affetta da tridimensionalità, cioè se ci sono più dimensioni di varianza che determinano il risultato ottenuto.
Si ha un test che permette di capire se la varianza contiene più dimensioni. La varianza tra tutti gli stimoli è uguale o è disomogenea perché, se questa è disomogenea non va bene: si deve, quindi, negare e cercare di capire se la varianza è prodotta da variazioni diverse negli stimoli, quando invece questa deve essere grossomodo uguale.
 - Test di Mauchly: calcola la varianza, quindi la p, che deve essere > 0.05 (non è significativo), viceversa se è < 0.05 si devono effettuare delle correzioni perché viene confermata la presenza di disomogeneità (si trova su Jamovi con il nome di "sphericity test")
- Correzioni:

Si effettuano nel caso in cui la p del test di sfericità sia < 0.05 e si devono correggere. Non si deve guardare il risultato di p ma si riposta il p dei test epsilon di Greenhouse-Geisser (quando il valore di Mauchly's < 0.75) oppure il test di Huynh-Feldt (quando il valore di Mauchly's > 0.75)
- Post-hoc:

Serve per capire che effetto produce la variabile indipendente:

 - Test di Tukey, se equivale a 0.001 la differenza prodotta è significativa in quanto produce delle differenze significative;
 - Test di Scheffe, test alternativo;
 - Test di Bonferroni, test alternativo più sofisticato e più recente.

Servono tutti per comparare le varie combinazioni di stimoli.

La tabella fa tutte le combinazioni possibili e calcola la differenza quando si passa da una situazione all'altra. La modifica dello stimolo produce delle differenze significative e produce un effetto che è anch'esso significativo.

Il valore soglia rimane sempre 0.05, sotto la quale è significativo.

- Estimate Marginal Means

Si accede alle opzioni delle medie marginali stimate, attraverso un grafico che comunica graficamente la differenza.

2. Between groups, in cui vi sono dei gruppi

- Parametri:

- F di Fisher:

non vi è solo n ma la distribuzione dipenderà dal numero di casi per gruppo, n , e numero dei gruppi, k ;

- Significatività: il p-level;

- Effect-size: eta-quadrato η^2 , quanta varianza è stata spiegata da questo modello, che deve essere $0 < \text{effect size} < 1$, compreso tra 0 e 1, più è vicino ad 1 più è forte, più è lontano da 1 più è debole.

- Precondizioni / Assumptions:

DV è cardinale e si distribuisce normalmente, si deve quindi fare un test di normalità:

- Normality test + Q-Q plot;

La varianza in ogni gruppo deve essere omogenea: varianza within-group equivalente.

- Test di Levene, homogeneity of variances test che non deve essere significativo;

- Post-hoc:

- Tukey's Honestly Significance Difference (HSD) test:

Aggiusta lo p-level in base alle differenze interne alle categorie della variabile indipendente.

Si possono effettuare le correzioni con il test di Scheffe o con il test di Bonferroni;

- Estimated Marginal Means

Per vedere graficamente le differenze quanto sono significative.

Si possono accorpare o eliminare le variabili poco significative.

3. Between groups, con più condizioni e 2 variabili:

Si tratta di un'analisi della varianza a 2 variabili, si parla di ANOVA fattoriale (non si tratta di un'analisi fattoriale) si tratta di un disegno in cui sono comprese più variabili:

Si hanno due variabili indipendenti con più categorie, mentre la variabile dipendente è una variabile cardinale.

Il disegno fattoriale, che implica l'impiego di tre variabili, assomiglia alla Moderation Analysis, (ricorda l'analisi tri-variata) in cui si studia l'interazione tra le due variabili. Si tratta di un disegno fattoriale 2x3, significa che la prima variabile indipendente ha due possibilità mentre la seconda variabile ne ha tre.

- Parametri:
 - Si considerano tre modelli:
 1. Variabile indipendente 1 che influisce sulla variabile dipendente
 2. Variabile indipendente 2 che influisce sulla variabile dipendente;
 3. Le due variabili indipendenti che interagiscono tra loro e che influiscono sulla variabile dipendente.
 - 3 x F di Fisher;
 - 3 x p-level;
 - 3 x effect-size: si calcola l'eta-quadrato η^2 ed anche l'eta-quadrato η^2 parziale che toglie gli effetti degli altri regressori.
 Si considera una parte della varianza come residuo/random (non dovuta all'effetto della variabile indipendente), ed una parte di cui non si considerano le origini.
 Con l'eta-quadrato η^2 parziale si considera una parte della varianza che non si sa spiegare, ed una parte che si deve distinguere nelle due variabili, le parti di cui è responsabile x_1 ed x_2 , e si deve capire quale ruolo queste due variabili hanno: si deve vedere non quanto x_1 o x_2 sono in rapporto con la parte spiegata ma con quella non spiegata.
- Presupposti:
 - La variabile dipendente deve essere cardinale e si distribuisce normalmente, si deve calcolare quindi la normalità;
 - La varianza è omogenea, si deve svolgere il test di omogeneità, si controlla la varianza within groups ed il test di Levene.
- Estimate Marginal Means
 Per un ulteriore confronto grafico, e si possono fare tre cose diverse perché si può vedere
 - Rapporto tra la x_1 e la variabile dipendente;
 - Rapporto tra la x_2 e la variabile dipendente;
 - Rapporto tra l'incontro tra x_1 e x_2 e la variabile dipendente.
 Al cambiare di una variabile indipendente, cambia anche l'altra variabile indipendente: su come si influenzano tra di loro si deve indagare.

Normalmente si prendono campioni più grandi, aumentando la complessità del disegno aumenta la necessità di prendere campioni più grandi.

4. Mixed factorial, ANOVA

- Vi sono due variabili indipendenti:
 - Manipolata between groups (A);
 - Manipolata within groups (B).
- Una variabile dipendente

È una matrice casi x variabili.

- Parametri:
 - 3 x F di Fisher, divisi tra la situazione within e between;
 - 3 x p-level;

- 3 x effect size, eta-quadrato η^2 parziale;
- Post-hoc (per la variabile A), come in between groups:
 - Tukey HSD;
- Post-hoc (per la variabile B), come in within groups, con le repeated measures:
 - Tukey;
 - Scheffe;
 - Bonferroni.
- Estimate Marginal Means, per un confronto grafico.

21/11/2024

Gli stimoli sono somministrati in due modi, between e within: per quanto riguarda il mixed factorial ANOVA.

- Assumptions:
 - Within groups, repeated measures
 - Test di sfericità, che misura la tridimensionalità, dipende dal caso studio perché se vi sono due variabili non può essere calcolato in quanto viene a mancare il presupposto della tridimensionalità stessa;
 - Test di Levene
 - Test dell'omogeneità: si possono fare delle correzioni che consentono di salvare l'esperimento ed aumentare le "p" e si può fare tramite un sacrificio cercando il gruppo che crea problemi ed eliminarlo dalla matrice.
Si vuole sapere se la variabilità all'interno di ciascun gruppo, se la varianza è omogenea e si fa in tutti i casi dell'esperimento: serve calcolare le misure di dispersione, cioè quando variano i valori in base alla media ("variance" su Jamovi). Si cerca qual è la varianza più diversa rispetto alle altre varianze.

Più le varianze sono simili tra di loro più il test di Levene sale, in quanto test di omogeneità.

Si elimina tramite "Filters", su Jamovi, con la quale si possono filtrare i dati da eliminare.

Validità, nel campo della ricerca sperimentale.

Se le cose che sono state misurate sono effettivamente così. Allora l'esperimento condotto ha dato un risultato valido? Cioè, quello che si scopre accade nella realtà?

La questione della validità ha a che fare con la realtà ed il rapporto con la realtà.

- **Validità interna**, ha a che fare con l'esperimento che è stato fatto, con quelle persone e quegli stimoli: la domanda è, il risultato ottenuto ha un rapporto con la realtà rispetto alla popolazione target studiata?
 - Validità di costrutto: riguarda il modo in cui si scelgono gli strumenti, le alternative e gli stimoli, e riguarda anche i concetti chiamati in causa.
Per studiare un concetto si trovano degli indicatori, ci si deve chiedere se si è costruito bene.

Le opzioni dell'esperimento sono delle opzioni realistiche?

- Validità di statistica: riguarda il campione stesso, la grandezza dello stesso, controllare se questo è probabilistico tramite il controllo della randomizzazione, tramite somministrazione e trattamento, quindi, controllare se si producono degli esiti "falsati" in base alla reattività dei soggetti alla figura del ricercatore (le persone che si sentono studiate ecc. perché il ricercatore ha il camice ecc.), forza e significatività, cioè, distinguere o meno la p dall'eta-quadrato, (la soglia di significatività è 0.05, scelta per convenzione in quanto è il rischio che viene accettato nel quotidiano di ogni soggetto umano, cioè l'intervallo di confidenza), errori, distribuzioni.
 - Validità causale: si verifica la connessione tra X e Y e si devono fare anche i controlli sulle Assumption/Precondizioni;
- **Validità esterna**: significa che si può estendere/generalizzare i risultati dell'esperimento alla realtà tutta, non si parla di stimoli in particolare, ecc. ma si parla a livello generale. Il rapporto di causalità trovato si deve confrontare con persone diverse, con contesti diversi e con i trattamenti ed esiti che devono essere simili a quelli di ogni giorno. Gli esperimenti cominciano con poche persone e poi si allargano.
- Esperimenti online a validità: online non si può manipolare l'esperimento nel senso che i dati che si hanno sono quelli e non si può cambiare una struttura tecnologica; quindi, si ha una serie limitata di dati sulla quale si deve basare l'esperimento. Ciò porta al problema dei costrutti.

ESPERIMENTI E QUESTIONI ETICHE

Il problema etico si è posto con la sperimentazione sugli animali.

Sono emersi tre criteri:

1. Rimpiazzare, cioè, se possibile farlo, utilizzare degli strumenti e dei metodi che siano meno invasivi;
2. Raffinare, si deve essere il più possibile innocuo in quanto non si deve nuocere ai soggetti che partecipano all'esperimento. Non deve creare un danno o se questo viene creato si deve porre rimedio al danno fatto. Nella ricerca sociale il danno può essere piccolo/medio/grande (la vita di una persona)

Se non si può evitare il rischio/danno si utilizza il consenso informato, trovando "un accordo": apre un'altra finestra.

3. Ridurre, il più possibile i soggetti dell'esperimento

Si possono allargare i campioni in un secondo momento.

MACHINE LEARNING

(def.) Un insieme di tecniche statistiche e informatiche volte a derivare modelli, classificazioni o previsioni di dati, eventi, comportamenti sulla base dell'esperienza o di esempi precedenti, calibrando e ottimizzando progressivamente i modelli stessi con dati nuovi.

Si tratta di diverse famiglie di tecniche che provano a simulare la difficoltà dell'apprendimento umano. Molte famiglie tendono a modellizzare, altre a classificare il mondo ed ordinarlo in categorie, ed altre ancora tende a prevedere dei valori sviluppando i modelli predittivi.

Ci sono grandi quantità di dati di cui le macchine hanno a disposizione, ed il lavoro delle macchine è di trovarne un modello/uno schema ed è fondamentale che vi sia un passato dei dati per costruire i modelli o farne delle previsioni.

Una volta costruiti i modelli, questi non sono mai definitivi, ma sono sempre aggiornati e ri-ottimizzati. All'interno di queste applicazioni vi si trova anche l'intelligenza artificiale, che recentemente è divenuta estremamente potente.

Il machine learning imita la facoltà umana dell'apprendimento. È il primo tassello di un'evoluzione che oggi è arrivata all'intelligenza artificiale generativa. È limitato, apprende e basta: la macchina impara ad associare attraverso gli algoritmi, tramite degli input e degli output. Essendo più potente di una persona può notare o scovare delle connessioni o dei pattern inaspettati ed utili. Questo approccio può essere messo in pratica in vari modi.

La svolta del machine learning si è avuta con lo sviluppo di internet.

Che rapporto esiste tra machine learning ed intelligenza artificiale?

- IA forte, la replica dell'intelligenza umana;
- IA debole, quella che svolge solo determinati compiti, tramite gli algoritmi.

Linea temporale:-> Machine learning -> Deep learning, processi con il quale le macchine imparano ma non si sa come imparano in quanto non si è a conoscenza degli algoritmi -> Generative AI, non solo lavora su dati che gli vengono messi a disposizione, ma genera testi di varia natura-> AGI, intelligenza artificiale generale, in cui la macchina comincia a ragionare.

Il principio che sta alla base di queste reti è ispirato dal funzionamento del cervello umano.

Tre modi di imparare:

1. Apprendimento non-supervisionato, cioè che si apprende/si conosce senza che vi sia qualcuno che ne spieghi il funzionamento (imparare esplorando e connettendo);
2. Apprendimento supervisionato, cioè che si apprende/si conosce tramite la presenza di qualcuno di esterno che ne spieghi il funzionamento (imparare da qualcuno che spiega, dagli esempi) significa che si deve avere a disposizione di questo "supervisore" che sia una persona, un testo ecc.;

creare un programma, unendo dati e risultati, per prevedere casi nuovi, spesso non interessano i meccanismi precisi attraverso i quali ciò avviene: deep learning.

Da un approccio theory-driven ad un approccio data-driven: prima ero lo scienziato che creava una teoria e cercava i vari dati ecc., al contrario si passa ad un approccio in cui con il machine learning si scaricano i dati dai vari data base e si chiede alle macchine di trovare qualcosa all'interno di questi dati.

La macchina deve costruire un software che sappia unire gli input e gli output, trovando una corrispondenza tra di loro. Nel deep learning, mentre nella machine learning si configurano gli algoritmi, al contrario è la macchina che si riconfigura automaticamente.

I dati sono organizzati in features (variabili indipendenti) e target/label (variabili dipendenti) e ne sono necessari tanti. Il supervisore è il target/label con la quale si effettua un controllo in base alle varie combinazioni: il problema è che vi devono essere dei dati già prestabiliti.

3. Apprendimento rinforzato, trial and error, in cui si svolge un'attività per il quale si può ricevere o meno una ricompensa (imparare dagli errori).

Obiettivo principale è la corretta classificazione o predizione di un risultato con un elevato grado di generalizzabilità. Si vede bene o male se la macchina ha effettuato una classificazione di cui si è già a conoscenza, e vedere quanto coincidono e quale sia il margine di errore.

APPRENDIMENTO NON SUPERVISIONATO

- Non richiede l'intervento umano;
- Obiettivo: esplorare il mondo ed effettuare delle classificazioni, cioè clusterizzare i casi in gruppi omogenei internamente ed eterogenei esternamente.

Si deve trovare un criterio per farlo, per clusterizzare.

- Clustering, nome classi scoperte ex post: si ha quando non si è a conoscenza, a priori, delle categorie da trovare;
 - Gerarchico, in cui si prevede un'organizzazione gerarchica, dal particolare al generale (agglomerativo) o viceversa dal generale al particolare (divisivo); Dal punto di vista computazionale molto esigente quando si incontrano i big data, si ricorre quindi a tecniche come:
 - Densità locale, si raggruppano le unità d'analisi considerando la caratteristica x_1 e x_2 in un grafico a due dimensioni, così che i gruppi internamente siano i più omogenei possibili e che esternamente siano i più eterogenei possibili; Si è dimostrato un approccio troppo banale, nelle scienze sociali che nei big data.
 - Partizioni ripetute, k-means
Inizia un processo iterativo per cui l'algoritmo effettua dei controlli per svolgere i raggruppamenti in maniera più efficace ed efficiente fino a quando non si raggiunge la massima omogeneità internamente ai gruppi e la massima eterogeneità esternamente ai gruppi, effettuando quindi degli spostamenti se è il caso
Ogni gruppo avrà un numero k di medie
 - Numero di cluster definito a priori:
 - Si fa riferimento alla teoria, teorie che si ispirano a quel fenomeno;
 - Prove ed errori, quindi provare varie k e vedere quale classificazione è quella ottimale;
 - Statistiche.
 - Tecniche per i centroidi: Lloyd, MacQueen, Hartigan-Wong, Forgy
Si valuta l'impatto computazionale della procedura
In un sistema si deve comunicare i criteri sulla quale il programma si deve basare, generalmente i criteri sono le variabili.
Le tecniche di clustering hanno ampio utilizzo nelle ricerche di marketing, mentre nelle scienze sociali la clusterizzazione serve ad effettuare un'estrazione dei tipi ideali weberiani.

- Classificazione, nome classi rigidamente definite a priori: si ha quando si è a conoscenza, a priori, delle categorie in cui inserire i dati.

Un centroide è una striscia di valori che contiene tutte le medie calcolate dall'algoritmo. Ci possono essere valori sia positivi che negativi in quanto le variabili sono state standardizzate, con media 0 e ... 1 e sono negativi se sono sotto la media.

Algoritmi, che stabiliscono le condizioni di partenza e di svolgimento:

- Hartigan-Wong, in cui i punti sono assegnati in maniera random ai centroidi, che si vanno spostando e sono loro che calcolano e ricalcolano la distanza dal centroide; è la tecnica migliore di clustering anche se è la più pesante a livello computazionale;
- Lloyd, più vecchio, che usa la tecnica delle k-means, il centroide si aggiorna prendendo la media dei punti appartenenti al gruppo, si assegnano i dati ai centroidi, questi si aggiornano, e si ricalcolano finché i centroidi non si spostano più trovando il proprio centro
- MacQueen, è una correzione/un miglioramento dell'algoritmo di Lloyd, per cui aggiorna immediatamente il centroide quindi dal punto di vista computazionale è pesante in quanto vede fare continuamente calcoli, ma crea delle partizioni ottimali quando si fa la cluster;
- Forgy, è un caso speciale dell'algoritmo Lloyd, in cui i centroidi iniziali non sono dei punti casuali ma sono delle persone vere, dei dati veri e reali, dalla quale si svolge lo stesso lavoro dell'algoritmo Lloyd.

Si deve valutare quindi l'impatto computazionale delle procedure, con i big data si utilizza tendenzialmente la tecnica di Lloyd.

"Number of random starting values" se i numeri sono casuali ogni volta che si fa un'analisi sarà diverso, Jamovi fa scegliere il numero delle analisi random e poi si cerca la media dei risultati ottenuti, conviene che sia un numero alto.

Queste tecniche di clustering non sono ... in quanto la classificazione non è controllata, si può fare una variabile cluster per vedere a quale cluster appartengono le nostre variabili

Una volta stimato il modello ogni caso avrà un output associato ... (vedi slides)

APPRENDIMENTO SUPERVISIONATO

Obiettivo dell'analisi è predire un target a partire dai features.

Serve a capire la categoria a cui si appartiene, binaria o con più ... che può essere un numero.

Se la variabile target (y) è una variabile numerica, allora gli algoritmi da usare saranno:

- Algoritmi di regressione (lineare, LASSO, ridge, reti neurali)

Se la variabile target è dicotomica/binaria, allora gli algoritmi da usare saranno:

- Algoritmo di regressione logistica;
- Algoritmo di classificazione (naive Bayes, alberi decisionali, random forest, support vector machine, reti neurali);

Se la variabile target è nominale, allora gli algoritmi da usare saranno:

- Algoritmo di classificazione (naive Bayes, alberi decisionali, random forest, support vector machine, reti neurali).

ALBERI DECISIONALI

Sono degli algoritmi che ci devono consentire di capire a qualche categoria corrisponde una persona/un oggetto/un'analisi.

“a quale categoria appartiene un elemento”: bisogna addestrare la macchina con degli esempi e successivamente il programma lavorerà da sé.

Un albero decisionale è una rappresentazione grafica del processo che porta, attraverso una serie di scelte, ad una categoria a scelta:

- Radici, rami e foglie

La spiegazione del meccanismo attraverso cui si arriva alla teoria è un meccanismo chiaro/esplicito. Differisce dal deep learning perché vi sono dei meccanismi sconosciuti attraverso cui il programma sceglie delle cose ma non si possono spiegare.

Tre categorie:

1. Se il target è dicotomico, si parla di alberi di classificazione (classification trees);
2. Se il target è cardinale, si parla di alberi di regressione (regression trees);
3. Esistono alberi di classificazione e regressione, se all'interno del target vi sono variabili cardinali ed ordinali.

Algoritmi principali:

- ID3, il più vecchio e quello che utilizziamo, la stessa logica di questo viene applicata e migliorata in quelli successivi;
- C4.5 e C5;
- CART (classification and regression trees);
- CHAID (Chi-square automatic interaction detection);
- QUEST (quick unbiased efficient statistical tree).

Come funzionano:

Quando si fa machine learning, le domande poste all'inizio sono domande più importanti, e quelle successive sono progressivamente meno importanti. Il problema si palesa nella scelta della variabile da scegliere tra le tante che sia la più importante?

Bisogna avere una misura statistica che costruisca questa gerarchia: progettare l'algoritmo significa trovare un modo per misurare la capacità classificatoria delle variabili:

- Guadagno d'informazione, cioè quante cose in più si possono sapere considerando quella variabile.
Fa parte dell'algoritmo ID3.
- Indice di Gini, cioè una misura dell'eterogeneità della distribuzione;
- Riduzione della varianza;
- Chi-quadrato.

L'algoritmo ID3 si basa, per calcolare il guadagno di informazione:

- Sulla misurazione dell'entropia, cioè misura del disordine all'interno di una distribuzione, misura l'incertezza di un sistema;
- Formula: $E = - \sum_{i=1}^k P_i * \log_2 P_i$
K è il numero di modalità che si ha di una variabile
 P_i sono le proporzioni ...
- Il guadagno di informazione è la differenza tra entropia totale ed entropia considerando un'altra variabile

28/11/2024

L'algoritmo ID3:

- Misurare l'entropia, è la misura del disordine di una distribuzione;
- Formula: $E = - \sum_{i=1}^k P_i * \log_2 P_i$
- Per misurare il guadagno d'informazione si devono misurare due entropie, l'entropia totale/generale/complessiva della variabile target e l'entropia quando si conosce l'altra variabile
"Binning" significa categorizzazione; se le categorie sono due si chiama dicotomizzazione, facendo diventare le variabili dicotomiche, se le categorie sono più di due si chiama binning.
Il guadagno di informazione è il guadagno che si ha nell'incertezza quando si prevede un fenomeno, conoscendo un'altra variabile: non cambia la formula ma cambiano le variabili dovendole unire facendo diventare la tabella una tabella di contingenza, chiamata tabella Pivot

Creare un modello di Machine Learning supervisionato:

Il primo passaggio da fare è quello di pulire e preparare i dati, in quanto questi se forniti dal web potrebbero non essere nella forma/dimensioni/caratteristiche che si cercano per il lavoro da svolgere. Si devono quindi mettere in conto determinate questioni:

- Presenza di missing values, che è un problema nelle analisi che si risolve:
 - o Eliminando la riga che presenta valori mancanti;
 - o Sostituire i valori mancanti con qualcos'altro, normalmente con la media/il valore medio, che può però ridurre la varianza
- Presenza di outliers, cioè valori troppo grandi/piccoli/strani che vanno controllati;
- Binning, se si hanno delle variabili cardinali si possono ricodificare così da farle diventare variabili nominali perché certe volte è più utile avere delle categorie al posto di una quantità eccessiva di valori: si fa quando si hanno più di due categorie;
- Confrontare le varie variabili, per cui si ricorre alla normalizzazione, riducendo le distribuzioni in un campo di variazione compreso tra 0 e 1;

- Effettuare la standardizzazione, cioè nuove distribuzioni che hanno media 0 e scarto quadratico/deviazione standard pari a 1;
- Riequilibrio delle classi sbilanciate, che fanno lavorare male gli algoritmi e si possono togliere alcune righe presenti in determinate categorie;
- Data reduction, tramite l'analisi fattoriale che accorpa le matrici casi per variabili facendole diventare delle "super variabili";
- Campionamento dei casi, cioè, estrarre dal campionamento dei dati una parte nel caso in cui i dati siano troppo grandi quando i computer non riescono a lavorare adeguatamente.

Il secondo passaggio è quello di addestrare la macchina, quindi si prende la matrice per intero e si divide:

- Hold-out method: si divide in due o tre parti:
 1. Training set, cioè l'insieme di casi che serve all'addestramento della macchina, si prende circa il 70% dei dati;
 2. Validation set, che serve per vedere, avendo già i risultati della variabile dipendente, se i dati previsti dal modello corrispondono con la restante parte coincide;
 3. Test set, si unisce spesso al validation set

Si devono stabilire, quando si costruisce il modello, chi sono le variabili vengono considerate come features e qual è il target, e a seconda di quest'ultimo si può usare uno o un altro algoritmo se il target è nominale o cardinale.

Si sceglie appunto quale algoritmo di Machine Learning, come ad esempio gli alberi decisionali o la regressione.

Successivamente, con il validation/test se la macchina funziona con i confronti tra previsioni e modello, se non è il risultato atteso si deve raffinare il modello così da dare una performance migliore.

Questi modelli vengono utilizzati per il business, quindi le macchine vengono distribuite come software all'interno di dispositivi e devices. Quindi l'ultimo passaggio è la distribuzione del modello, deployment.

Per distribuire i modelli si devono valutare:

- Calcolando il fitting dei modelli rispetto ai dati, cioè, controllare il modo in cui il modello calza rispetto ai dati
 Deve funzionare con i dati anche nuovi, se è troppo preciso per un modello può non essere adatto per una molteplicità di modelli.
 L'obiettivo che si vuole raggiungere è quello dell'appropriate fitting, cioè abbastanza generale per comprendere la maggior parte dei casi.
 L'over-fitting è un modello di fit adeguato a un modello solo, presenta un'alta validità interna ma una scarsa validità esterna.
 L'under-fitting invece è un modello di fit troppo semplice.
 Si devono trovare delle soluzioni, che equivalgono in un compromesso tra semplicità e complessità, i cosiddetti trade-off che si trovano basandosi sul numero dei features e sulla grandezza del validation/test set.

Valutare i modelli discreti in modo formale. I modelli discreti prevedono o un output binario o che prevedono un output nominale. Si deve escludere la regressione che prevede come output dei numeri.

- Si costruisce una matrice di confusione, che incrocia valori osservati e valori previsti;

es.

		Output modello (prediction)		
		Negativo	Positivo	
Valore reale	Negativo	5.689 (veri negativi)	555 (falsi positivi)	6.244 Tot. negativi reali
	Positivo	758 (falsi negativi)	1.139 (veri positivi)	1.897 Tot. positivi reali
		6.447 Tot. negativi previsti	1.694 Tot. positivi previsti	8.141

Le caselle in giallo sono quelle in cui coincidono valore reale e predizione. Le altre caselle con quelle in cui la predizione non coincide con il caso reale, quindi, sono i casi in cui la macchina ha sbagliato, ha previsto in modo scorretto gli esiti.

Gli indici che si possono calcolare per vedere quanto funziona il modello sono:

- Accuracy, accuratezza del modello, che si misura prendendo: $\frac{\text{previsioni corrette (caselle arancioni)}}{\text{totale casi (casella verde)}}$
- Precision, precisione, che è una misura che si concentra sui veri positivi cercando di capire se le previsioni positive sono corrette: $\frac{\text{veri positivi (previsioni positivi corrette)}}{\text{totale positivi reali}}$
- Sensitivity o recall, sensibilità o richiamo, la cui attenzione è rivolta ai veri positivi ma sulle previsioni che sono state fatte: $\frac{\text{veri positivi (previsioni positivi corrette)}}{\text{totale positivi previsti}}$
- Specificity, specificità, la cui attenzione si sposta sulle previsioni negative corrette: $\frac{\text{veri negativi (previsioni negative corrette)}}{\text{totale negativi reali}}$
- Proporzione di falsi negativi sul totale dei negativi previsti, questa cosa segna il mancato allarme: $\frac{\text{falsi negativi}}{\text{totale negativi previsti}}$
- Proporzione di falsi positivi sul totale dei positivi previsti: $\frac{\text{falsi positivi}}{\text{totale positivi previsti}}$

Insieme a queste misure, che sono ognuna che fa una cosa diversa, sono state pensate delle misure articolate che mettono insieme alcuni di questi parametri:

- Kappa di Cohen, che misurano più questioni, ovvero:
 - o Concordanza tra valori reali e previsioni;
 - o Varia tra 0 e 1, che deve essere >0.4;
- F-measure, o F1 o F-score, che serve all'ottimizzazione degli algoritmi, quando si vogliono considerare previsione (previsione positivi) e sensibilità (peso dei falsi negativi)
 - o Molto criticata in letteratura;

Raffinare il modello:

1. Strategia Iterativa, per valutare se l'effetto era quello atteso, ed in caso contrario continuare ad aggiustare;

2. Strategia computazionale, che consiste nel creare tanti modelli, anche generandoli in modo random, per provare a scovare il modello che funziona meglio, prende il nome di “ensemble learning” o apprendimento d’insieme

Vi sono tre approcci:

- a. Boosting e gradient boosting;
- b. Bagging, cioè bootstrap aggregation, cioè grandi quantità di estrazioni casuali ed i migliori di questi modelli vengono abbinati.
I modelli sono random sia per quanto riguarda i features sia le righe.
- c. Stacking, in cui si accatastano i modelli, si clusterizzano secondo un principio agglomerativo/divisivo.

La curva ROC, Receiver Operating Characteristics, vengono utilizzate dai radar che però non sono molto precisi. La curva ROC si presenta proprio come una curva in un sistema di asse cartesiani e man mano che la curva sale e si ingobbiisce significa che la macchina prevede bene i casi: più si avvicina ad un valore che equivale a 1 più il modello fa pochi errori, o non ne fa.

Sull’asse delle x si mette il tasso di falsi positivi/falsi allarmi, mentre sull’asse delle y si mette il tasso dei veri positivi/sensibilità.

Si deve calcolare il valore dei falsi positivi (FP) e dei veri positivi (VP), cioè le coordinate, e si deve fare per ogni passaggio della soglia negativo/positivo.

METODI DIGITALI E BIG DATA

- Digital turn: pervasività di social media, piattaforme, applicazioni mobili e algoritmi nei vari contesti sociali (cultura, istruzione, economia, lavoro, trasporti, ospitalità, ecc.) hanno portato alla creazione di una società digitale;
- La sociologia digitale tratta ambienti digitali come campo di studio nel quale descrivere e spiegare: sé, self-branding, identità, corpo, relazioni sociali e di potere, strutture, istituzioni, disuguaglianze, reputazione, pratiche culturali e di consumo, ecc.
- La sociologia digitale si basa su tre principi:
 1. Si deve studiare oltre ai media anche le relazioni degli attori sociali tra loro e con attori non-umani nella costruzione sociale della realtà (dati, algoritmi, metriche) da logica one-to-many (un messaggio mandato ad una massa che doveva interpretare e reagire) ad una logica many-to-many (anche le persone sono oggetto del messaggio che possono interagire con questo per poi mandarlo ad una massa che deve interpretare e reagire);
 2. Continuità tra reale e virtuale, online e offline;

03/12/2024

3. Rifiuto sia delle prospettive tecno-deterministiche, per cui la tecnologia che impone dei comportamenti, sia delle prospettive che propongono il superamento della teoria tramite i big data

I metodi della sociologia sono i “Digital methods”, cioè delle tecniche e dei metodi che stanno a cavallo tra la sociologia digitale e i media studies. Si ha un focus su Internet, in cui si individuano le tecniche per studiare la società e viene studiato tramite cinque concetti sensibilizzanti (cioè, quei concetti che ispirano una riflessione) e sono comunità, pubblico, folla, rappresentazione del sé, user

come device. Sulla base dei concetti sensibilizzanti si gioca il lavoro dei metodologi online, che lavorano sia utilizzando vecchie tecniche adeguati ai nuovi contesti, sia inventando nuove tecniche:

- Approccio nativo: approccio metodologico ispirato direttamente dai media digitali, cioè che si possono fare solo con i media digitali e con i materiali prodotti dai media digitali. Consistono nello studiare gli ambienti digitali ed intenderli come risorsa metodologica: si devono studiare tre cose:
 - o In che modo le relazioni sociali diventano delle forme sociali interessanti: quando si interagisce con gli altri vengono create delle strutture, che possono avere delle forme;
 - Si aprono degli scenari, ad esempio, come vengono scelti tag, hashtag e link e a chi fanno riferimento;
 - o Studiare le strutture semantiche, cioè reti di significato, prodotte dagli ambienti digitali;
 - o Studiare il modo in cui queste relazioni e strutture si mantengono o esauriscono, il tempo di vita di queste aggregazioni;
 - o Studiare le “affordance” del mezzo, cioè, ogni digital medium ha le sue caratteristiche e peculiarità e queste influenzano ciò che le persone possono fare con il medium e ciò che dicono nel medium: cosa permette di fare il mezzo.
- Metodi virtuali: adattamento delle tecniche tradizionali ai mutati scenari tecnologici.
- Approccio quali-quantitativo e triangolazione, per la quale si conciliano gli approcci qualitativi e quelli quantitativi.

Campi d'applicazione dei metodi digitali

- Consumi, fandom, macro e micro-celebrità;
- Come gli algoritmi di raccomandazione strutturano i gusti culturali, che finiscono per alimentare le eco-chambers in cui si trovano le stesse cose o troppo simili;
- Circolazione e impatto sociale delle fake news;
- Discussioni su temi sociali e politici, ed interessano anche le degenerazioni come ad es. hate speech, cambiamento climatico ecc.;
- Frammentazione della sfera pubblica;
- Conseguenze della proliferazione dei bot, account fake, sulle campagne elettorali;
- Aumento della sorveglianza e contrazione della privacy;
- Platfomizzazione del web, cioè il web che è diventata una piattaforma di proliferazione di servizi e di streaming che consentono la disponibilità rapida di diverse cose.

Raccogliere i dati digitali

- Cosa
- Quando

Un criterio per limitare lo spazio dei dati a disposizione si cerca in base alle keyword, parole chiave. Ogni chiave che si sceglie racconta determinate cose, e quindi in base a come si scelgono le keyword si otterranno dei dati di conseguenza, ed un problema perché cambiando le chiavi cambia il mondo di riferimento.

Un'altra cosa che si trova come dato sono i metadati, cioè i dati che parlano dei dati e si deve capire quali sono e dove sono, e soprattutto se servono.

Geolocalizzazione, può capitare che i dati siano effettivamente geolocalizzati ed il problema è se fidarsi o meno.

Per quanto tempo si prendono i dati, cioè quale finestra temporale, e streaming tramite il quale si possono prendere enormi quantità di dati.

Politiche di accesso ai dati delle piattaforme, cioè chi può avere accesso a quali e quanti dati:

- Si parla di academic divide in quanto avviene una discriminazione verso i ricercatori per via delle spese da affrontare per svolgere le ricerche

Raccogliere i dati digitali

- Etnografie online;
- Database esistenti;
- Web mining, cioè, scavare nel web ed è un approccio nativo perché segue il mezzo. Si può fare in tre modi diversi:
 1. Web crawling, cioè la creazione di un elenco di link validi e utili, si parte da dei link web e a partire da questi.
Ha un significato linkarsi e ricostruire la rete consente di ricostruire il mondo disegnato da appartenenze e riferimenti.
Si parte dai Semi (i link iniziali) e si va poi a cercare in profondità i legami tra questi semi ed i legami dei legami ecc.: se si va troppo in profondità perde senso.
I domini digitali sono dei mondi che suggeriscono che al loro interno c'è un'uniformità dei punti di vista.
Si può fare anche con il data miner.
 2. Web parsing, cioè, si individua la morfologia del web e tirare fuori da questo schema i contenuti e poi i metadati.
È possibile scaricare testi dai social media o da strutture? www.exportcomments.com
 3. Web scraping, cioè ritagliare ed accumulare dati e per far ciò si utilizza il "data miner" che è un programma che permette di ritagliare pagine web specialmente se queste sono sistemate in modo ordinato e funziona come plug-in di Google chrome. Vi è anche "out scraper".

05/12/2024

Tutti i concetti che si estrapolano si possono ricostruire gli universi simbolici collegati con questi concetti; si può scoprire anche se da questi si ripartono ulteriori concetti: diventano delle reti semantiche, per vedere chi è collegato simbolicamente con che cosa.

Con l'outscraper viene creata direttamente una matrice casi variabili.

Ci sono anche altri strumenti per raccogliere i dati che sono:

4. Spigots: cioè, un tappo o uno stuzzicadenti che si infila nelle tane degli insetti per tirar fuori delle colonie che saranno poi studiati.
La metafora è dell'andare a prendere casi da studiare all'interno di un universo nascosto su cui lavorare.
Ci sono due spigots importanti:
 - a. NodeXL, è a pagamento ma molto economico. Si infila all'interno di social network e altre piattaforme per tirar fuori i dati.

Ci si può fare analisi testuale ma quello per cui è nato Nodexl è la network analysis, posizionati in modo randomico ma si possono disporre secondo determinati criteri centro-periferia o tramite sottogruppi: serve a studiare le strutture sociali che emergono dalla rete che possono essere più o meno coese.

In-degree è il prestigio sociale.

Out-degree è l'influenza.

- b. Communalystic, è a pagamento ma si può accedere alla versione gratuita per studenti/insegnanti. Si possono raccogliere dati da youtube, twitter con delle limitazioni, telegram, reddit.

Nella prima pagina fa vedere una curva di attenzione da inizio anno fino alla data in cui è stato scaricato il link; si vede anche una word cloud che fa vedere tutte le parole più utilizzate; un emoji cloud in cui si vede il sentiment espresso nei commenti e ancora più giù si vede una classifica top ten di account che hanno commentato al link di riferimento.

Colleziona i dati tramite l'assegnazione di un nome al data set e si aggiunge il link della barra youtube del video di riferimento.

Accesso a tutte queste risorse, generalmente c'è bisogno di una porta di accesso che sono state previste dai programmatori e si chiamano:

- API, application programming interfaces

È necessario avere delle credenziali, delle chiavi di accesso e c'è bisogno di alcune conoscenze di programmazione, è una barriera d'accesso per chi non ha conoscenze a riguardo ma si possono ottenere tramite determinate applicazioni.

Si deve quindi avere l'accesso, tramite procedure di autenticazione che spesso sono:

- o OAuth, open authorization

Un altro provider di API è google e si deve creare tramite cloud.google.com nella voce "console". Si possono realizzare dei progetti assegnandogli un nome, si cerca "(piattaforma di riferimento) + data API" si abilita e successivamente si possono creare delle credenziali con dati pubblici e viene creata la chiave, e si copia incolla in communalystic o simili.

Analizzare i dati significa lavorare con:

- Metriche, numeri
- Network analysis, relazioni e link
- Analisi del contenuto, testi

Obiettivi:

- Visualizzare le reti d'interazione, tramite NodeXL e Gephi (quando si hanno già i dati): significa non solo vedere i nodi ed i loro collegamenti ma si possono modificare le misure dei nodi (vertex) e si possono cambiare le scale da più piccole a più grandi e viceversa, per vedere la misura dei più rilevanti (prestigiosi/influenti).

Si può fare una cluster analysis e si modifica il layout e colori (fanno vedere plasticamente l'importanza ed i legami) dividendo i legami in gruppi e vedendo anche chi non ha legami.

Si deve tener conto delle forme che sono delle stelle, gli influencer sono le palle grandi sono più grandi più sono potenti e cercati.

- Individuare gli attori più popolari e autorevoli e il loro tipo, NodeXL e Gephi;
- Esplorare conversazioni online, word clouds, tramite wordclouds.com e Communalystic;

- Misurare il sentiment, sentiment analysis, o la tossicità, cioè l'emotività positiva o negativa riguardanti il nostro caso studio (commenti, post, ecc.), tramite Communalystic che lo fa in tedesco, francese, inglese e portoghese;
La tossicità è un commento rude/irrispettoso che probabilmente fa abbandonare la discussione alle persone: severa, nei confronti di un'identità, gli insulti, le minacce, le parolacce, ecc.
Mostra l'andamento nel tempo della tossicità.
Si possono vedere le stesse cose ma che hanno un'accezione positiva.
- Scoprire i temi specifici e la loro popolarità, gli argomenti di cui si è parlato, tramite Communalystic e text mining.
Si possono controllare i singoli cluster in Communalystics e fa vedere una rappresentazione spaziale.
- Visualizzare reti di parole e significati, tramite NodeXL e Gephi;
- Effettuare analisi diacroniche

BIG DATA

Sono big data tutti quei dati che non possono entrare in un hard disk/computer (50 TB); non possono stare al loro interno.

Caratteristiche:

La letteratura classica afferma:

- Volume: sono dati enormi;
- Varietà: non sono solo dati numerici, sono testi, immagini, audio, ecc.;
- Velocità: dati trasferiti in tempo reale da un posto all'altro del mondo.

Altri studiosi hanno aggiunto:

- Alta risoluzione;
- Non-reattività: essendo creati da noi senza la presenza di un ricercatore, l'assenza di questa figura determinano dei dati reali/spontanei;
- Diacronicità: sono dati che nel tempo si sviluppano e possono essere analizzati.
- Dati strutturati: che verosimilmente sono organizzati in matrice per i quali si può utilizzare il linguaggio SQL, Structured Query Language;
- Dati non strutturati: sono dati non SQL, non organizzati in matrice, tag, markup, XML, JSON JavaScript Object Notation, noSQL;

Chi produce big data?

Non sono dati creati da noi ma sono in mano alle grandi corporation, alle grandi compagnie dei dati: banche dati, Amazon ecc.

Dove si conservano i dati?

Prima stavano all'interno di grandi infrastrutture; ci è stata una svolta nella conservazione dei dati che è il Commodity hardware quindi anziché nelle infrastrutture nei computer e distribuito in rete, venivano gestiti tramite un software open source che si chiama Hadoop. Questo software deve essere controllato da tecnici informatici. Questa necessità di conoscenze ha portato ad uno sviluppo ulteriore per facilitare le cose, tramite il Cloud computing, ritornando alle grandi infrastrutture.

Questi digital methods, compresi i big data, presentano dei limiti:

- Digital divide: chi ha accesso alle risorse informatiche, sono richieste delle autorizzazioni, in alcuni paesi del mondo vi è la censura;
- Digital inequality: le persone che hanno accesso ad Internet come lo usano, per lavorare con i dati o in maniera elementare;
- Limitato accesso ai dati e agli algoritmi;
- Servizi digitali e fini commerciali, molti servizi che si usano per scaricare dati sono stati pensati per fini commerciali e non per fini sociali e di ricerca sociale;
- Debole validità di costrutto: contrapposizione tra custom-made e ready-made, si vuole costruire un concetto sulla base di determinati indicatori ma determinate variabili possono essere mancati e ci si deve accontentare di ciò che c'è in rete;
- Incompletezza e non rappresentatività: i dati possono essere incompleti, possono mancarne alcuni, e si deve vedere quanto quei dati siano rappresentativi perché non sono campioni costruiti secondo la teoria classica del campionamento e non si può generalizzare, cioè non si può estendere all'intera popolazione.
 - o Analisi post-demografiche, fa riferimento al fatto che spesso con i dati internet non si hanno dati come genere, età, provenienza, titolo di studio, lavoro ecc. con cui si fanno le classiche ricerche sociali, e se sono presenti non vuol dire che siano veritieri;
 - o Dark web e Deep web, tutta quella parte del web che non è indicizzata o che è nascosta in cui ci svolgono attività illecite
- Sporcizia, sono dati sporchi perché sono dati:
 - o Non veritieri;
 - o Errori casuali;
 - o Errori sistematici, ci sono momenti in cui argomenti vengono trattati di più o di meno;
 - o Bot, agenti non umani;
- Instabilità: i dati fluttuano e variano velocemente;
- Confusione algoritmica e non-neutralità degli ambienti digitali, affordances;
- La non-reattività non impedisce la desiderabilità sociale;
- Privacy e vincoli etici.

Etica della ricerca

Man mano che si procede con l'avanzamento di tecniche di raccolta di dati online, il potere dei ricercatori cresce più velocemente ma alla crescita di questo potere non fa da contrappeso la regolazione di regole e leggi; la società sarà sempre più avanti della legge e si potrebbe abusare di questo potere. In più quando le leggi esistono, essendo un campo molto complesso, possono essere incoerenti tra di loro, contraddicendosi, e si possono sovrapporre.

Si può fare un uso dei dati secondario non previsto.

Vi sono quattro principi, ricavati da documenti "Rapporto Belmont" che riguarda la ricerca su soggetti umani, e "Rapporto Menlo" che riguarda la ricerca con ICT, dalla quale si possono evincere questi principi:

1. Rispetto per la persona: si oggettiva tramite il consenso della persona al trattamento dei dati, ci sono vari modi per ottenere il consenso;

2. Beneficialità: si deve considerare il rapporto rischi/benefici per cui quello che si fa non deve cagionare danno a nessuno e deve essere fatto in modo da ottenere i più ampi benefici possibili;
3. Giustizia: può essere declinato in modi diversi:
 - a. Proteggere le persone più deboli, riguarda maggiormente gli esperimenti diretti con le persone;
 - b. Accesso di tutti ai benefici: quello che viene realizzato deve essere accessibile a tutti;
 - c. Compenso: se c'è deve essere proporzionale al contributo che hanno dato;
4. Rispetto per la legge e l'interesse pubblico: si deve essere conforme alle regole, se ci sono, e si deve garantire a tutti la trasparenza/pubblicità del lavoro svolto.

Conseguenzialismo e deontologia: criticità

Corrente filosofica del consequenzialismo, rientrano nelle etichette del liberalismo e dell'utilitarismo, di Bentham e Mill, che tiene conto delle conseguenze dei nostri fini. Il fine è migliorare lo stato del mondo o la felicità.

Il problema del consequenzialismo è la deontologia, di Kant, che si collega all'imperativo categorico secondo cui la legge morale si trova all'interno di ognuno ed è inappellabile, alla quale non si può disobbedire. L'approccio deontologico sostiene che se vi è un principio questo deve essere assolutamente rispettato, e presenta un problema, cioè, che un dovere etico deve essere indipendente dalle conseguenze: vedere i mezzi.

Si dovrebbe quindi trovare un equilibrio tra mezzi e fini.

Criticità:

- Il consenso informato non è una scelta dicotomica, sì/no, e non tutte le parti di una ricerca lo richiedono
 - o Può essere difficile, rischioso o falsante ottenerlo;
 - o Si può richiedere un consenso ex post.
- Rischio informativo, cioè non tanto il danno immediato dell'esperimento ma se la diffusione di informazioni possono recare danno, causato a terzi per la diffusione di informazioni
 - o Anonimizzazione dei dati;
 - o Condivisione solo tra studiosi;
 - o Protezione dei dati;
 - o Attacchi di re-identificazione: attacchi hacker che consentono di risalire ad una persona attraverso l'incrocio di alcuni dati.
- Il principio del rispetto della persona non dovrebbe prevalere automaticamente:
 - o Principio di precauzione;
 - o Principio standard di rischio minimo.

L'idea è di evitare la paralisi e di bloccarsi, si è diffuso il concetto di integrità contestuale, applicando restrizioni, modalità e controllo.

I comitati etici e le loro disfunzioni, le scelte etiche della ricerca vengono affidati a dei comitati che riunendosi prendono delle decisioni e che spesso sono dei comitati che attraverso la burocrazia vi è un allargamento dei tempi; in più possono essere presenti diverse posizioni per cui non si riesce a prendere una decisione e si finisce per essere esageratamente distanti dalla realtà.

10/12/2024

TEXT MINING & ANALYTICS

Text mining è una sorta di termine ombrello che comprende una serie di tecniche.

Definizione: è una serie di tecniche per l'estrazione di conoscenza da risorse testuali digitali.

Queste tecniche consentono di lavorare sui testi in due modi:

- Approccio etico: cioè, dall'esterno, ed analizzare i testi ponendosi dall'esterno significa elaborare una serie di nozioni/concetti/aree di analisi/idee che poi verranno utilizzate per leggere i testi;
- Approccio emico: cioè, prevede una prima lettura/un primo studio dei testi per poi derivare da questi delle aree di analisi/concetti.

Non per forza questi devono essere separati.

Text mining:

- Analisi del contenuto, content analysis, che consiste in un approccio quantitativo al testo, contando le parole o le categorie;
- Sentiment analysis, che studia il contenuto emotivo all'interno dei testi;
- Topic modeling, per individuare all'interno dei testi dei temi/issue/argomenti che li caratterizzano;
- Classificazione dei testi, TC Text Classification;
- Clustering;
- Recupero dell'informazione, information retrieval e knowledge management, che consiste nel cercare all'interno dei testi degli oggetti/elementi che possono essere di varia natura, personaggi ecc. per fare delle analisi statistiche;
- Linguistica computazionale e Natural Language Processing, NLP, che consiste nel capire il linguaggio di ogni giorno al di là dei formalismi del testo:

Si studia:

- La ricchezza lessicale;
- Variazione lessicale;
- Leggibilità;
- Comprensione;
- Traduzione automatica;
- Ecc.

Fasi del text mining:

1. Raccolta dei documenti e costituzione del corpus, cioè l'insieme dei testi presi in considerazione per svolgere l'analisi;

Ci si deve porre un problema, cioè, vedere in che misura questo corpus riesce a rappresentare tutta la popolazione esistente o se si tratta di testi ottenuti.

- a. Popolazione teorica;
- b. Popolazione accessibile.

I testi digitali si possono raccogliere tramite dei web parser (Export comments, Data Miner, Import.io, NodeXL, Communalytic, RSS cioè Really Simple Syndication o Rich Site Summary), API varie.

2. Pre-processing: i testi si devono sistemare e pulire rendendoli adatti ai software.

Devono attraversare dei processi di:

- a. Normalizzazione, cioè, modellati attraverso la rimozione di errori e di refusi, rimozione di punteggiatura e numeri, conversione di tutte le parole in minuscolo;
- b. Tokenizzazione, cioè, dividerlo in parti così che le parole diventino un'unità di analisi chiamata unità testuale o token, e la tipizzazione;
- c. Si rimuovono le stopwords, le parole vuote che non hanno un significato ben preciso come le congiunzioni, gli articoli, le preposizioni;
- d. Lemmatizzazione, operazione che consiste nel trasformare le parole in lemmi, cioè quelle parole che si trovano all'interno di un dizionario che non sono declinate e non sono coniugate: fa diminuire le parole da analizzare;
- e. Stemming, che assomiglia alla lemmatizzazione, consiste nella rimozione della forma flessa di una parola lasciando solo le radici delle parole: crea molta confusione;
- f. Tagging, cioè, mettere i tag alle parole, possono essere di varia natura:
 - i. Part-of-speech, POS: si possono taggare le parole in base il ruolo che hanno dal punto di vista grammaticale;
 - ii. Entity: riconoscimento di entità all'interno dei testi, che possono essere luoghi, persone o organizzazioni;
 - iii. Sentiment: può essere positivo, negativo o neutro.
- g. Disambiguazione: se ci sono termini che sono sfuggiti a tutto questo lavoro e presentano delle ambiguità, si devono rendere con forme grafiche diverse o si aggiunge un segno distintivo;
- h. Potatura della matrice, pruning, anche per evitare overfitting: si fa per rendere il numero delle parole più limitato stabilendo una soglia oltre la quale vengono eliminate dall'analisi; si tolgono le parole che sono in minor numero perché risultano obsolete.

3. Organizzazione dei dati: il modo più diffuso è quello di costruire un Vector Space Model, e se i dati non si organizzano non sono più trattabili.

I dati devono essere sistemati in una matrice casi per variabili. Il VSM è un modo di rappresentare formalmente un documento e l'approccio più utilizzato è il Bag of Word (BOW) prendendo tutte le parole, mettendole all'interno di una "borsa" così che ogni documento venga rappresentato da una lista pesata di parole che prende il nome di vettore.

Ogni parola è una dimensione del testo ed ha un certo peso e si devono però attribuire questi pesi attraverso:

- a. Modello di rappresentazione booleano 0-1;
- b. Modello Term Frequency, cioè, attribuire la frequenza di un termine ovvero quante volte quel termine si presenta all'interno del testo e si può anche relativizzare trasformando la frequenza in una percentuale;
- c. Modello Term Frequency-Inverse Document Frequency (TF-IDF): consiste nel pesare le parole cosicché le parole più specifiche di un testo abbiano un valore/peso maggiore rispetto ad altre. Si calcola prima il Term Frequency relativo e poi si svolge la formula:

$$\text{peso } w_{ij} = \left(\frac{\text{occorrenze termine } w_i}{\text{totale termini documento } D_j} \right) * \log_{10} \frac{n \text{ documenti}}{n \text{ documenti con termine } w_i}$$

w= word

i= è la parola i esima

j= è il numero del documento

Questo modello aiuta a stabilire la frequenza di un termine e anche in più importanti, che sono più informativi.

Queste matrici si dice essere sparse perché presentano un sacco di 0 perché le parole sono tante e non tutte le parole sono presenti in tutti i testi: lo spazio vettoriale è quindi in genere sparso e con elevata dimensionalità.

La matrice documenti x termini (DTM, Document Per Term) che si costruisce alla fine del percorso è la base per le analisi successive, da questa inizia il text mining e in più le intelligenze artificiali generative partono da queste.

Si usano anche rappresentazioni BOW, bag of words, ma si mettono anche nelle matrici le n-gram cioè sintagmi.

4. Analisi del contenuto, content analysis, applicazione di un algoritmo che consente di fare le analisi.

Consiste nello scomporre i testi per esplorare, contare, classificare e valutare il contenuto.

Sono tre i tipi di analisi:

- a. Analisi delle frequenze: consiste nel provare ad esplorare il contenuto di un testo attraverso le frequenze delle parole; l'idea è quanto più una parola è presente all'interno di un testo tanto più essa sarà importante. Osservando le liste di parole si possono provare ad individuare delle keyword, delle parole chiave, e si può provare anche a raggrupparle in categorie. Un'altra applicazione tipica è vedere come un certo oggetto del discorso viene trattato nel tempo lungo i vari testi: si chiamano queste applicazioni "curve di attenzione". Significa costruire le nuvole di parole;
- b. Analisi delle contingenze: l'attenzione si rivolge non più alle singole parole ma alle coppie di parole per capire se chi comunica tende ad unire due concetti o più sistematicamente due parole; ciò può svelare dei veri costrutti semantici ma anche psicosociali.

Si trova calcolando il coefficiente del coseno:

$$c(x, y) = \frac{f(x, y)}{\sqrt{f(x)} * \sqrt{f(y)}}$$

Cioè, il rapporto tra le volte in cui si trovano le due parole insieme fratto la radice della frequenza della parola x con la radice quadrata della frequenza della parola y.

- c. Analisi degli asserti valutativi, una specie di sentiment analysis ante litteram, fatta dal ricercatore grazie alla propria capacità valutativa.

Si prende un testo, si divide in frasi, viene letta ogni frase e il ricercatore deve stabilire se il contenuto è positivo, negativo o neutro: è un giudizio espresso dal ricercatore e quindi è arbitrario; per risolvere il problema dell'arbitrarietà si svolge questo giudizio con diversi ricercatori e si misura la complementarità, cioè la media dei giudizi.

Cioè, si può svolgere tramite un sito intitolato Voyant.

5. Misurazione della performance del modello, cioè quanto il modello costruito dice delle cose interessanti per quanto riguarda i testi.

Sentiment analysis

Definizione: si usa per valutare il contenuto emotivo di un testo o di un corpus di testi, ma questo può essere calcolato solo se estraiamo, misuriamo e riassumiamo i contenuti testuali con cui si lavora. Viene misurato rispetto oggetti o persone che possono essere di ogni tipo. Mira quindi ad estrarre, misurare e riassumere opinioni e sentimenti soggettivi nei riguardi di oggetti o persone, contenuti in testi di varia natura, viene fatta utilizzando metodi computazionali.

La sentiment analysis ha avuto questo successo perché nei media digitali si è diffusa la possibilità di diffondere opinioni, valutazioni, giudizi e recensioni e si pone il problema di analizzare il contenuto di questi lavori e quindi di analizzarne il contenuto emotivo. Sono sia la sentiment analysis e opinion mining che sono sinonimi.

Vi sono dei problemi, cioè di controllare se il sentiment sia:

- Esplicito, per cui il problema non si presenta perché essendo esplicitato è riconoscibile;
- Implicito, quindi, vi è un problema perché il sentiment è nascosto e le macchine possono non riconoscere il sentiment e la sfida è il costruire strumenti di sentiment analysis che siano in grado di andare oltre l'esplicito.

Vi sono dei fondamenti teorici dell'approccio del sentiment analysis, che ha ereditato concetti che provengono dalla psicologia delle emozioni e dagli studi di comunicazione; un'altra matrice di questo approccio deriva dalla teoria delle decisioni, branca dell'economia e delle scienze cognitive che spiega come si prendono le decisioni e le decisioni di acquisto nello specifico; c'è una corrente della psicologia cognitiva che si chiama appraisal theory che afferma che quando l'uomo prova delle emozioni queste non sono sempre le stesse comunque ed in ogni contesto ma quello che si prova dipende da una serie di variabili, non sono emozioni che si provano indipendentemente dal contesto ma sono guidate da una serie di fattori come obiettivi, aspettative o dal controllo che si ha su queste emozioni, come di gestiscono, o da altre persone influenzano le emozioni.

Si applica nel marketing, nel decision making, nelle analisi predittive, le elezioni, ecc.

Dal punto di vista tecnico la sentiment analysis si configura come una tecnica di classificazione, cioè si hanno delle categorie (positivo, negativo, neutro) e si deve cercare di attribuire un'etichetta ad un testo. Siccome si tratta di un problema di classificazione si svolge tramite il machine-learning:

- Supervisionato, avendo già delle etichette applicate ai testi con cui la macchina impara ad effettuare analisi;
- Non supervisionato, si fa ricorso a dei lessici che funzionano come liste di parole che hanno significato positivo, altre che hanno significato negativo, si prende un testo e si contano le parole del testo che fanno parte del primo lessico (positivo) e le parole che fanno parte del secondo lessico (negativo), si fa un bilancio e se prevalgono le parole positive allora il testo è positivo, o al contrario se prevalgono le parole negative allora il testo è negativo. Eventualmente ci sono degli algoritmi più sofisticati che fanno ricorso a delle regole che cercano di capire il contesto in cui le parole vengono utilizzate.

I livelli possono essere diversi alla quale si possono attribuire le etichette positivo, negativo o neutro; si applicano a:

- Tutto il documento per intero;
- Ad ogni frase;

- Ad un oggetto del discorso all'interno della frase.

Un aspetto poco esplorato ma molto interessante è quello non solo di distinguere la polarità del sentiment, cioè se è positivo, negativo o neutro, ma si capisce anche in che misura il sentiment è positivo o negativo: se è tanto positivo o tanto negativo.

Ci sono degli strumenti da utilizzare:

- Opinion Lexicon, per la lingua inglese, che è un dizionario elementare che contiene circa 6800 parole; si trova all'interno di NodeXL;
- VADER, Valence Aware Dictionary and Sentiment Reasoner, che è basato sul lexicon e su delle regole che servono a riconoscere i contesti in cui si utilizzano le parole. È stato studiato appositamente per i social media.
Si basa sul Lexicon ma usa le regole che sono procedimenti insiti nell'algoritmo che consentono di capire il contesto di quella parola;
- TextBlob, che si trova su Communalityc, è basato su Python e fa accedere tramite API a compiti di NLP; oltre a fare sentiment consente di fare tagging, estrazione di nomi, classificazione, traduzione automatica, ecc.

Il problema è di programmare in Python per utilizzarla, o affidarsi a Communalityc;

Tecniche e librerie si possono combinare per controllare se convergono e se si confermano a vicenda.

Per trovare un Lexicon italiano si può trovare nell'ebook "guida al text mining e alla sentiment analysis con R" di Valentina Porcu.

12/12/2024

Limiti

- Ambiguità del linguaggio e contesti: il linguaggio può essere troppo ambiguo per essere trattato computazionalmente:
 - o Ironia;
 - o Sarcasmo;
 - o Figure retoriche;
 - o Parole non sono categorizzate perché considerate o parole neutre.
- Gergo, dialetto e slang: non vengono riconosciuti dai dizionari ufficiali e standardizzati;
- Rumore linguistico, cioè il fatto che si scrive qualcosa con degli errori di ortografia o si scrive con modo molto condensato, mettendo asterischi, comunque tutte quelle forme grafiche non classificate.

Anche frasi senza parole con contenuto emotivo possono esprimere sentiment, questione del sentiment implicito. Alcuni dizionari che usano anche le regole riescono a tirar fuori il sentiment e altri no, ma in generale siccome queste cose si compensano nei vari testi è possibile che il sentiment emerga ed il fatto è che non si è precisi e ci sono dei grandi margini di errore.

Paternalità delle affermazioni, questione dell'attribuzione di frasi, parole, discorsi o ragionamenti:

- Bot e spamming: ci sono una serie di contenuti online che in realtà vengono fatti da robot linguistici o accade lo spamming, cioè lo scrivere la stessa cosa per inquinare il web, una pagina, ecc. che non serve per capire cosa c'è nella realtà nel dibattito pubblico.

Quindi chi scrive queste cose? Si possono capire i meccanismi linguistici al di là della paternità/maternità delle questioni?

Si è capito che il sentiment viene usato molto nelle ricerche di mercato, ma vi è una differenza tra ricerca di mercato, orientata al profitto, e ricerca sociale, orientata alla conoscenza scevra da ogni interesse: queste due cose contano quando si ricerca l'opinione delle persone, si cerca globalmente l'opinione/il parere che circonda un determinato brand ecc. La ricerca sociale vuol sapere le cose in modo preciso così da tirar fuori teorie, ipotesi, vi sono problemi di affidabilità e validità. La ricerca sociale è più esigente, tant'è che la sentiment analysis non è utilizzatissima nella ricerca sociale.

Vi sono dei vantaggi che si possono sfruttare:

- Sui social, ma specialmente su Twitter si deve essere sintetici quindi le persone useranno meno parole e porta un controllo sul linguaggio che torna utile ai ricercatori;
- Le persone automaticamente offrono un servizio di riassunto quando usano gli hashtag nei loro post, hashtag con cui si può lavorare.

TOPIC MODELING

Tecnica che consente di individuare gli argomenti/temi di cui si parla all'interno di un testo. Serve a riassumere il contenuto delle cose che vengono scritte/dette.

Si ha un corpus, formato da vari documenti, da cui vengono estratti temi e argomenti:

- Permette una lettura amplificata per corpus giganteschi a fronte di una grande quantità di testi;
- Ogni documento che fa parte del corpus può contenere diversi topic e questo numero di topic viene scelto a priori dal ricercatore, ma poi viene rivisto:

Ciò si fa attraverso algoritmi:

- o Latent Dirichlet Allocation, LDA, è il primo degli algoritmi ma presenta dei problemi;
- o Correlated Topic Model, CTM, che migliora la comprensione dei topic facendo ricorso ad una struttura gerarchica, riconoscendo dei temi annidati in temi più grandi;
- o Latent Semantic Analysis, LSA, in cui la tecnica è fattoriale e funziona attraverso una sorta di analisi fattoriale per i testi in cui vengono individuate delle dimensioni, orizzontale e verticale, dopodiché vengono collocati in un sistema di assi cartesiani e le bolle di parole vengono collocate in questo sistema.

L'output dei primi due algoritmi è:

- o Fornite dal computer una serie di liste di parole per ogni topic con cui il ricercatore deve leggere le parole all'interno delle liste e cercare di capire il tema comune delle parole e così dà il nome al cluster;
- o I vari documenti poi vengono assegnati al/ai topic: qui si fa una distinzione tra:
 - Mixed membership model: in cui un documento può appartenere a più topic;
 - Hard clustering: in cui un documento può appartenere ad uno ed un solo topic, che torna utile nel caso di machine learning in cui si mette un'etichetta ad un insieme di dati.

Generalmente viene prodotto un grafico chiamato "mappa di calore" o heat map, che fa vedere delle probabilità comprese tra 0-1 e più è grande più il colore si avvicina al rosso, più è piccolo più si avvicina al giallo.

Limiti della tecnica del topic modeling:

- Il problema delle foglie di tè: le liste di parole che vengono fuori dall'analisi sono come le foglie del tè rimangono dopo l'infuso, si tira fuori dalle parole qualcosa che esattamente non c'è;
- L'ordine delle parole non viene considerato, che invece è importante anche con la punteggiatura con cui il senso della frase può cambiare. Sono necessarie quindi delle tecniche che considerino l'ordine delle parole e la punteggiatura;
- Il problema dei testi corti: è difficile fare un topic modeling quando ci sono troppe poche parole, togliendo le stop word e la punteggiatura; sono quindi state sviluppate delle tecniche come la single topic LDA, stLDA-C.

Classificazione dei testi

Si tratta di una tecnica che è una generalizzazione della sentiment analysis, nel senso che le categorie possono cambiare rispetto a positivo, negativo e neutro.

Mentre il topic modeling rientra in un approccio emico, dall'interno, qui è al contrario, è un approccio etico prima si individuano i temi, le categorie e poi si fa il raggruppamento, dall'esterno.

Applicazioni:

- Quando si ha una grande raccolta di documenti digitali o digitalizzati vi può essere la necessità di recuperarli tramite librerie e raccolte digitali;
- News filtering: si deve filtrare per argomento determinate categorie;
- Opinion mining: in testi positivi, negativi e neutri;
- E-mail: di spam o meno.

È un termine di confine con il machine learning, si possono fare classificazioni single o multi-label, una o più etichette, e queste possono essere supervisionate oppure no.

Nel caso della classificazione supervisionata si fa ricorso al machine learning; si deve costruire il dataset di addestramento, cioè quella serie di dati che sono già etichettati, si possono utilizzare degli algoritmi, come gli alberi decisionali, naïve Bayes, i support vector machines, SVM. Successivamente si fa una misurazione della performance con la matrice di confusione per capire in che misura il classificatore funziona.

In caso di classificazioni multi-label, non binarie, si dicotomizzano le classi, costruendo vari modelli e si mettono a paragone.

Reti semantiche e loro sviluppi

Non sono tanto interessanti le reti semantiche ma molto più importanti sono i loro sviluppi.

Sono state utilizzate nelle scienze cognitive che sono una branca della psicologia che studia la mente umana come se fosse un computer. Le reti semantiche sono state utili proprio per rappresentare le strutture mentali. Questo stesso modo di rappresentare il pensiero venne utilizzata dalla prima intelligenza artificiale. Un altro campo di utilizzo delle reti semantiche è stata l'informatica.

Una rete semantica è una rappresentazione di temi o concetti, chiamati nodi, collegati fra loro attraverso relazioni logiche di vario tipo; i legami sono in genere dei legami logici che hanno un nome. È utilizzata molto nei software CAQDAS, Computer Assisted Qualitative Data Analysis Software, con cui si può attraverso queste rappresentazioni, sviluppare delle teorie. Rappresentare il pensiero e gli schemi cognitivi delle persone o dei testi è il compito di queste reti, che sono delle reti semantiche: al loro interno vi sono concetti e isotopie, cioè una specie di area di significato a cui si attinge quando si parla con gli altri, che sono legate in catene, sono concatenate. Il loro utilizzo nella ricerca sociale è quello di provare a rappresentare in modo semplice teorie, ipotesi e tassonomie.

Nelle reti semantiche non è presente la matrice di adiacenza, che è fondamentale per svolgere una network analysis: si deve trasformare il grafico in tabella così da renderlo analizzabile computazionalmente, possono anche non essere valori binari. Non si costruiscono misure di rete.

L'intuizione è stata quella di utilizzare per i legami e le relazioni tra le parole, la matrice di adiacenza: si passa dalle reti semantiche a due evoluzioni, sono due modi diversi di prendere in considerazione la matrice di adiacenza per andare oltre le reti semantiche:

1. Analisi di reti di parole: il ricercatore da un contributo minimo, non è presente nella costruzione della rete.
 - a. Si può partire da una matrice che si può chiamare "attori x parole" per vedere quante volte gli attori hanno usato determinate parole. A partire da questa matrice si può generare un'altra matrice "parole x parole" e diventa così una matrice di adiacenza, c'è un legame tra le parole e ciò significa la sintassi, e questo dice come si costruiscono le frasi. A partire di queste matrici si possono costruire delle reti di parole e si può ricostruire il grafico di partenza diventando informativo perché si possono trovare addensamenti di parole, ecc. diventa un'analisi del testo che considera il testo come un reticolo di relazioni.
 - b. Si può partire da tecniche fattoriali, partendo da una matrice "parole x testi", vengono utilizzati per individuare topic e nessi tra i topic e si usano software come Spad-T, T-Lab, R. Nella comunicazione serve per tirar fuori il senso dei testi a livello grafico senza che sia necessario leggere i testi stessi. Si utilizza un software chiamato Wordij.

Vi è il problema dell'ordine delle parole, responsabile del significato, e della loro intensità e le proposte correttive:

- Catene markoviane, con cui a partire di una parola viene detto qual è la probabilità delle parole precedenti e successive a quella presa in considerazione, con cui si possono costruire delle frasi ideali con le parole precedenti o successive;
- Word-network analysis;
- Analisi delle comunità semantiche;
- Mappe cognitive;
- Center resonance analysis: analisi dinamica per lo studio dei discorsi che si appoggia al software Cawdrad.

È un approccio emico, dall'interno, è esplorativo.

2. Analisi testuale di rete, network text analysis: il ricercatore ha un ruolo importante anche interpretativo, l'intervento umano è massimo perché è il ricercatore che sceglie/seleziona quali sono le parole da studiare, le keyword, gli hashtag; anche la codifica dei legami viene fatta dal ricercatore. Dopo di ciò si costruisce la rete semantica e le misure di rete: è un approccio etico, dall'esterno.

Approcci:

- Analisi di rete degli asserti valutativi;
- Map Analysis;
- Knowledge graphs;
- Analisi reticolare del discorso: è una tecnica che mira ad analizzare il contenuto latente della comunicazione, intendendo il discorso come un'attività sociale attraverso cui si producono significati, che equivale al non detto.

Avviene perché con il discorso si costruisce la realtà che sta attorno all'uomo e non è detto che questo sia lo stesso per tutti o che sia comunicabile, c'è un non detto che consiste nel fatto che vi sono delle prassi che fanno parte del contesto che viene riconosciuto in un determinato modo.

Diventano importanti gli elementi contestuali, cioè dove avvengono le cose, del testo e l'interpretazione: è importante la definizione della situazione per capire anche cosa consegue dalla situazione in cui ci si ritrova.

- Si studia la sintassi, le forme retoriche, come i partecipanti dinamicamente si pongono l'uno verso l'altro;
- Ci sono anche i temi e questioni latenti che hanno a che fare anche con il modo in cui è organizzata la società, i rapporti di potere tra le persone.

Si provano, nell'etnografia digitale, a ricostruire le identità discorsive degli utenti e le narrazioni collettive e le sue frasi, e le rappresentazioni socioculturali.

Etnografia digitale

Non vi è un adattamento delle tecniche tradizionali al mondo digitale, è nata appositamente per i nuovi ambienti digitali. Vi è un approccio dei digital methos appunto: follow the medium, e capire come la tecnologia influenza i comportamenti e le interazioni online.

Non è più rivolta a una cultura o comunità ben definita: interessano i pubblici, persone estranee che si incontrano nella rete perché hanno in comune qualcosa, di cui tutti possono fruire; pubblico quindi come connessione tra estranei, i quali sono temporaneamente uniti da intensità emotiva e un interesse verso un oggetto comune. Si utilizzano delle tecniche quali-quantitative come la sentiment analysis e la social network analysis, che si può fare di persone/profili ma anche del testo.

Tipo	Concezione del Web	Metodologia	Contesto di ricerca	Esempi
Etnografia dei mondi virtuali	Spazio parallelo alla vita reale	Etnografia tradizionale	Mondi virtuali Identità digitali Reale/virtuale	MMORPG
Netnografia	Spazio comunitario	Metodi virtuali: adattamento al contesto <i>online</i>	- Comunità <i>online</i> - Culture del consumo - <i>Fandom</i> e «religioni civili»	Studi su consumatori e <i>fan</i>
Etnografia digitale	Spazio di interazioni varie ed effimere	<i>Digital methods</i>	Pubblici <i>online</i> Sfera pubblica	Analisi dei <i>social media event</i>